CONEIXEMENT, RAONAMENT I INCERTESA

# Aprenentatge Bayesià: Naïve Bayes

Luis Vera Albarca
1637397

# ÍNDEX


INTRODUCCIÓ ..... 3
Objectius ..... 3
Materials ..... 3
PART C ..... 4
Enunciat ..... 4
Resolució ..... 4
Anàlisi de resultats ..... 6
PART B ..... 8
Enunciat ..... 8
1. Ampliar el conjunt de train ..... 8
Resolució ..... 8
Anàlisi de resultats ..... 9
2. Diferents mides de diccionari ..... 14
Resolució ..... 14
Anàlisi de resultats ..... 15
3. Mida de diccionari fixe, diferents conjunts de train ..... 21
Resolució ..... 21
Anàlisi de resultats ..... 22
Preguntes ..... 28
PART A ..... 29
Enunciat ..... 29
Resolució ..... 29
Anàlisi de resultats ..... 29
1. Ampliar el conjunt de train ..... 30
2. Diferents mides de diccionari ..... 33
3. Mida de diccionari fixe, diferents conjunts de train ..... 36
CONCLUSIONS ..... 39

# INTRODUCCIÓ

La pràctica 3 de la assignatura Coneixement, Raonament i Incertesa presenta el problema de l'aprenentatge bayesià. En particular, el focus es posa en la classificació de tweets com a positius o negatius, una tasca comuna en el camp del processament de llenguatge natural i l'anàlisi de sentiments. L'objectiu és **aplicar mètodes bayesians per dissenyar un sistema de filtratge automàtic que sigui capaç de determinar el sentiment expressat en cada tweet**, utilitzant com a base una base de dades de més d'un milió de tweets processats. El problema s'organitza en tres nivells de dificultat: A (sobre 10), el qual és la dificultat màxima, B (sobre 8), que és la dificultat mitjana, i C (sobre 6), que és la dificultat més baixa**.**

## Objectius

Els objectius d'aquesta pràctica són:

- **Aplicar l'aprenentatge bayesià en** el context d'una **aplicació de classificació de tweets** segons el seu sentiment.
- **Aprendre a utilitzar els mètodes de validació** explicats a teoria.
- Ser capaç d'**aplicar la teoria en problemes reals**.

## Materials

Per realitzar aquesta pràctica, es disposa dels següents materials:

- **SentimentAnalysisDataset.csv:** Aquest fitxer conté la **base de dades original** de tweets, amb textos no processats.
- **FinalStemmedSentimentAnalysisDataset.csv:** Aquest fitxer conté la **base de dades processada**, on els tweets han estat tractats prèviament mitjançant el Lancaster Stemmer de Python, eliminant signes de puntuació i reduint les paraules a les seves arrels, facilitant així el procés d'anàlisi.

# PART C

## Enunciat

En aquest exercici es demana **implementar una xarxa bayesiana per classificar els tweets** del conjunt de test **com a positius o negatius**. Per a la primera part de l'exercici, s'haurà d'utilitzar tota la base de dades de tweets disponible i el diccionari generat a partir del conjunt de dades d'entrenament. El diccionari s'haurà d'obtenir processant les paraules presents en els tweets del conjunt d'entrenament, i després s'aplicarà la xarxa bayesiana per realitzar la classificació en el conjunt de test, determinant el sentiment associat a cada tweet.

## Resolució

La resolució d'aquest problema ha seguit les següents passes:

1. **Lectura de la base de dades**: S'ha carregat el dataset anomenat *'FinalStemmedSentimentAnalysisDataset.csv'*, que conté la base de dades processada.
2. **Preprocessament**: S'ha decidit eliminar les instàncies que continguin valors *NaN*, ja que la quantitat d'aquestes files respecte al total és molt petita. A més, s'han convertit tots els tweets a minúscules i s'han concatenat les paraules.
3. **Divisió del dataset en dades de *train* i de *test***: S'ha realitzat una separació del dataset, dividint-lo en un conjunt de dades d'entrenament (*train*) i un conjunt de validació (*test*) en una proporció de 80% per a *test* i 20% per a *train*. També s'ha utilitzat el paràmetre *stratify* en funció de la classe per obtenir conjunts de dades equilibrats.
4. **Generació d'un diccionari**: A partir del conjunt d'entrenament, s'ha generat un diccionari on cada paraula diferent és una clau (*key*), i el valor associat és un altre diccionari amb dues claus: *'pos'* i *'neg'*, que contenen els comptadors de quants tweets amb la paraula són positius i quants són negatius.
5. **Càlcul de probabilitats**: A partir de les classes del conjunt d'entrenament, es calculen les probabilitats totals que les classes siguin positives o negatives. A més, amb la informació del diccionari generat a l'apartat anterior, es calculen les probabilitats condicionals per a cada paraula. Així, s'obtenen dos diccionaris: un amb les probabilitats de les classes positives i negatives, i un altre amb les probabilitats de cada paraula en relació amb les classes positiva i negativa.

6. **Prediccions a partir de Bayes**: A partir dels diccionaris de probabilitats generats, es realitzen les prediccions per a cada tweet del conjunt de test aplicant les probabilitats condicionals de Bayes. Les prediccions es guarden en una llista per ser comparades posteriorment amb les classes reals del conjunt de test, i així poder avaluar el model de predicció.
7. **Mètriques:** S'han escollit les següents mètriques per avaluar el rendiment del model de predicció:
    - **Accuracy:** Aquesta mètrica retorna la proporció de prediccions correctes sobre el total de prediccions. Pot ser enganyosa si el model està desbalancejat, així que calcularem altres mètriques per complementar a aquesta.
    - **Precision:** Aquesta mètrica mesura la proporció de prediccions positives correctes respecte al total de prediccions positives fetes pel model. És útil per entendre quant de fiable és el model quan prediu que un tweet és positiu.
    - **Recall:** Aquesta mètrica mesura la proporció de casos positius que han estat correctament identificats pel model.
    - **F1-score:** Aquesta mètrica combina la precision i el recall en una sola mesura que busca un equilibri entre les dues. Es calcula com la mitjana harmònica de la precision i el recall.
    - **Specificity:** Aquesta mètrica mesura la proporció de casos negatius que han estat correctament identificats pel model.
8. **Avaluació del model. Cross-Validation:** s'ha optat pel k-fold cross-validation com mètode per avaluar el model per davant d'altres estratègies com el leave-on-out degut a que té una millor eficiència computacional, mantenint alhora una estimació robusta del rendiment del model gràcies a la seva divisió iterativa de les dades en entrenament i validació. S'ha treballat amb un valor de k = 5 i s'han calculat les mitjanes resultants de calcular les mètriques de l'apartat anterior per a cada iteració.



# Anàlisi de resultats

## Matriu de confusió

En primer lloc, s'analitza la matriu de confusió generada a partir d'una predicció del model amb una partició de train i test 80%-20%, amb l'objectiu d'obtenir una visió general del seu rendiment. Com es pot veure a la figura 1, hem obtingut els següents resultats:

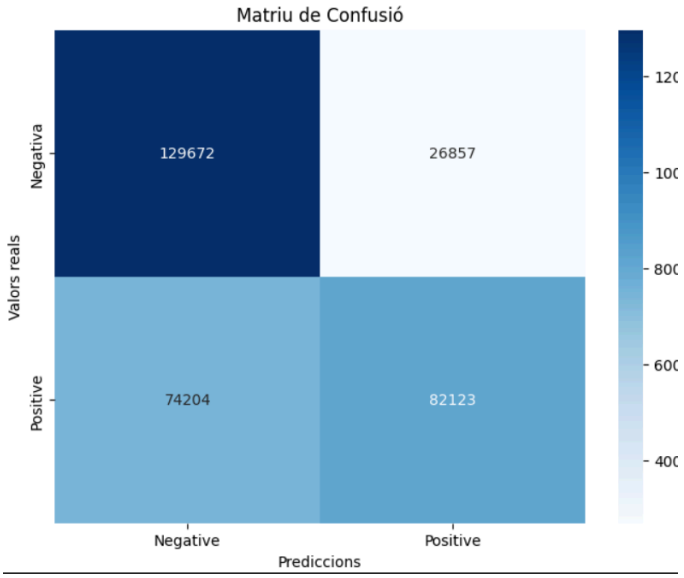



**Figura 1: Matriu de confusió.**

Amb aquestes dades, podem afirmar que el model té un bon rendiment en la predicció de les classes negatives. Tanmateix, el seu rendiment en la predicció de les classes positives no és excepcional. Per entendre millor aquest comportament, avaluarem les mètriques comentades anteriorment.

- **True Positive (TP):** 82.213
- **False Positive (FP):** 74.204
- **True Negative (TN):** 129.672
- **False Negative (FN):** 26.857

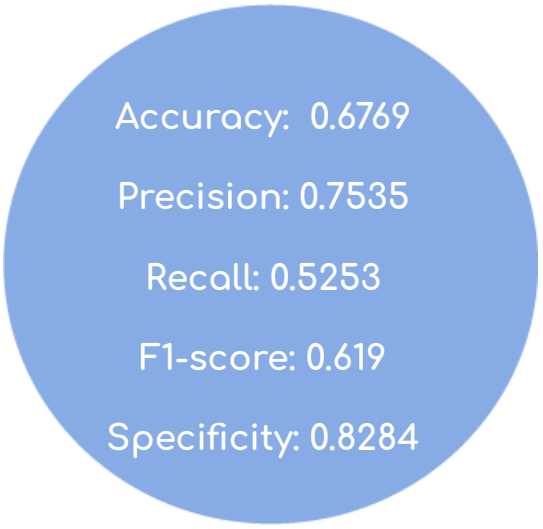



**Figura 2: Mètriques resultants del k-fold CV**

## Mètriques

Un cop obtinguda la matriu de confusió resultat d'una única predicció, es realitza un k-fold cross-validation per obtenir una avaluació més robusta del model i s'obtenen els resultats corresponents a les mitjanes obtingudes dels valors que retorna cada predicció del cross-validation, les podem observar a la figura 2.

**Fortaleses del model:**

- **Alta precisió:** Quan el model classifica un tweet com a positiu, normalment té raó.
- **Alta especificitat:** El model és eficient en detectar tweets negatius.

**Debilitats del model:**

- **Baix recall:** El model deixa escapar molts tweets bons, cosa que pot ser un problema si és important identificar-ne tants com sigui possible**.**

**F1-Score moderat:** La combinació de precisió i recall suggereix que, **tot i tenir una bona precisió, el model podria millorar si aconseguís detectar més tweets positius sense sacrificar massa la precisió.**

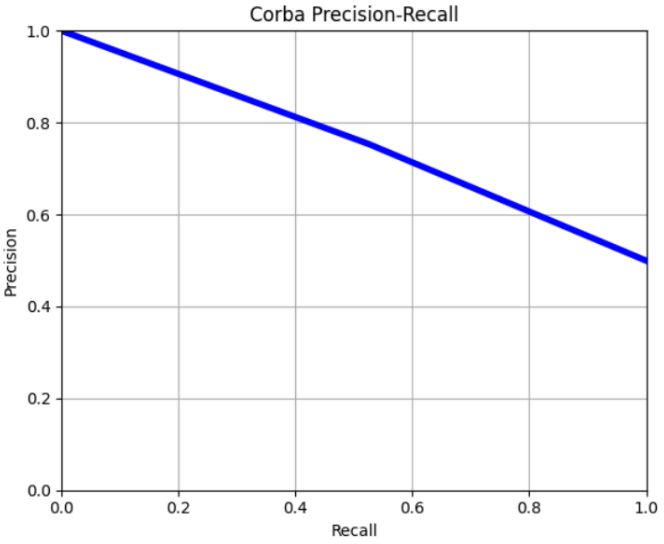



*Figura 3: Corba Precision-Recall*

A la figura 3 es pot observar la relació entre el *precision* i el *recall* o **corba *precision-recall***. El model té una ***precision* força alta quan el *recall* és baix, però aquesta baixa a mesura que el *recall* augmenta**, però sempre mantenint-se per sobre de 0.5

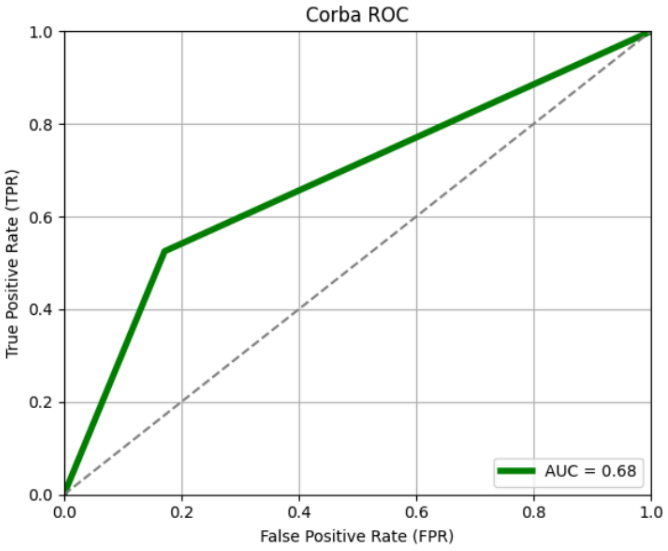



**Figura 4: Corba ROC**

A la figura 4 es pot observar la **corba ROC**, que **mostra la relació entre la taxa de veritables positius (TPR) o recall i la taxa de falsos positius (FPR)**, que correspon al complementari de la mètrica *specificity.* L'àrea sota la corba o **AUC mesura la capacitat global del model per discriminar entre les classes**, sent 1 el valor ideal i per sota de 0.5 un valor dolent. El nostre model té un **AUC de 0.68**, que ens indica que **el model té un rendiment moderat**, però millorable. Que el valor no sigui més alt es deu, com hem vist anteriorment, a la sensibilitat o *recall* del model.

# PART B

## Enunciat

En aquest exercici es demana **avaluar la xarxa utilitzant conjunts de train i diccionari de diferents mides**, analitzant tres estratègies principals: primer, **ampliar el conjunt de train**, on es podrà determinar l'interval, observant com l'augment del nombre de tweets provoca també un canvi en la mida del diccionari; segon, **fixar el conjunt de train però utilitzar diferents mides de diccionari** per valorar com aquesta variable afecta l'entrenament del model; i finalment, **utilitzar sempre la mateixa mida de diccionari, però modificant el conjunt de train** per veure com afecta aquesta variació a l'entrenament de la xarxa.

# 1. Ampliar el conjunt de train

## Resolució

La resolució d'aquest problema ha seguit les següents passes: (les definicions de les passes 1, 2 i de la 4 a la 6 es poden trobar a la secció de l'informe corresponen a la part C)

1. **Lectura de la base de dades**
2. **Preprocessament**
3. **Determinar les particions de train i test:** A la part C de la pràctica vam treballar amb una partició de dades d'entrenament i de validació amb un 80% de train i un 20% de test. Aquest problema ens demana ampliar el conjunt de train, per tant, s'ha determinat que s'avaluarà el model utilitzant les següents particions: 20% train - 80% test, 40% train - 60% test, 60% train - 40% test, 80% train - 20% test i 95% train - 5% test per evaluar com varia el rendiment del model en funció de les particions *train-test*.

**Per a cada partició de train i test:**

4. **Divisió del dataset en dades de *train* i de *test***
5. **Generació d'un diccionari**
6. **Càlcul de probabilitats**
7. **Fer prediccions a partir de Bayes**
8. **Obtenir mètriques per avaluar el model**

# Anàlisi de resultats

En aquest apartat s'analitzaran les mateixes mètriques que a l'apartat C per a cada una de les diferents opcions de particions *train-test* que s'han determinat per aquest exercici i es compararan els resultats. Com els resultats corresponents a la partició 80% train - 20% test ja els tenim de la part C de la pràctica, tant sols es realitzaran la resta de càlculs.

## 20% train - 80% test

### Matriu de confusió

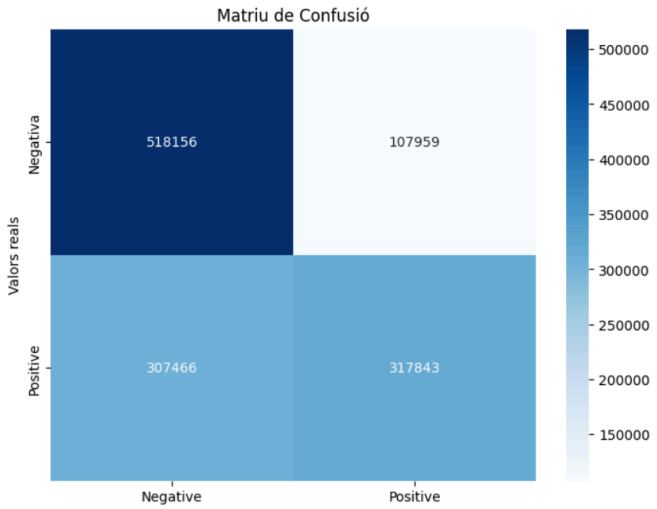



**Figura 5: Matriu de confusió 20% train.**

- **True Positive (TP):** 317.843
- **False Positive (FP):** 307.466

### Mètriques

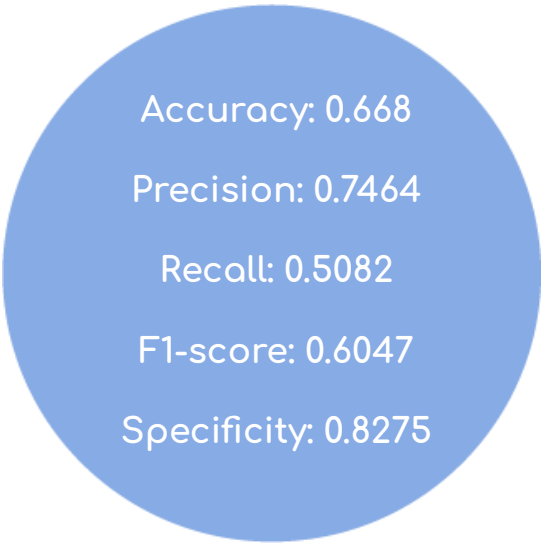



**Figura 6: Mètriques 20% train.**

- **True Negative (TN):** 518.156
- **False Negative (FN):** 107.959

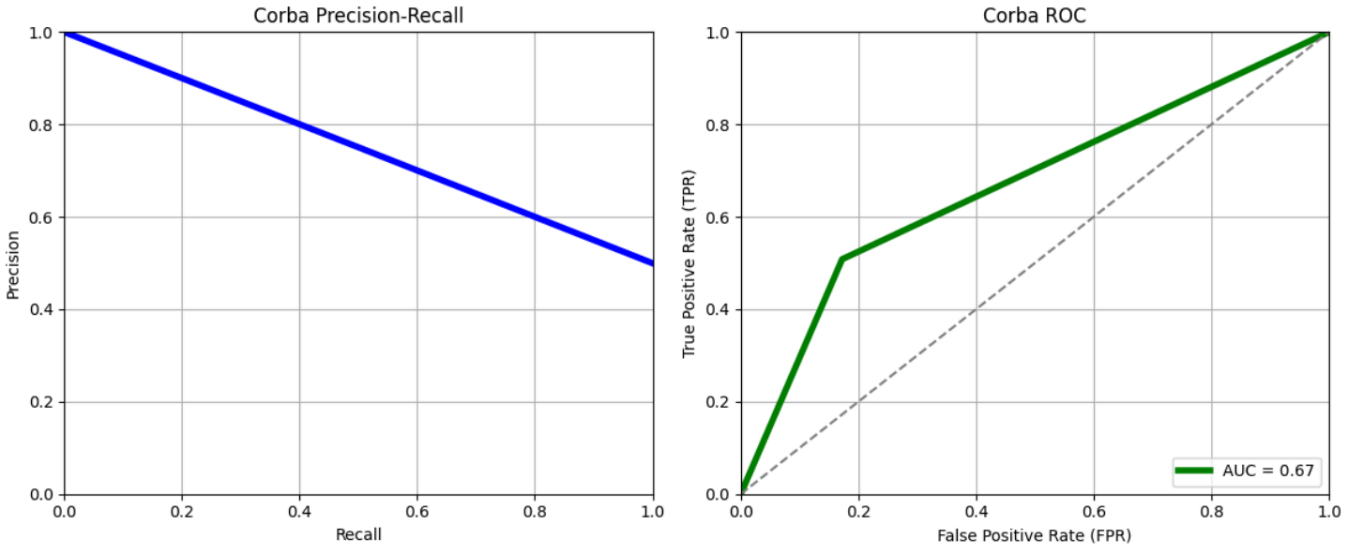



**Figura 7: Corbes P-R i ROC 20% train.**

## 40% train - 60% test

### Matriu de confusió

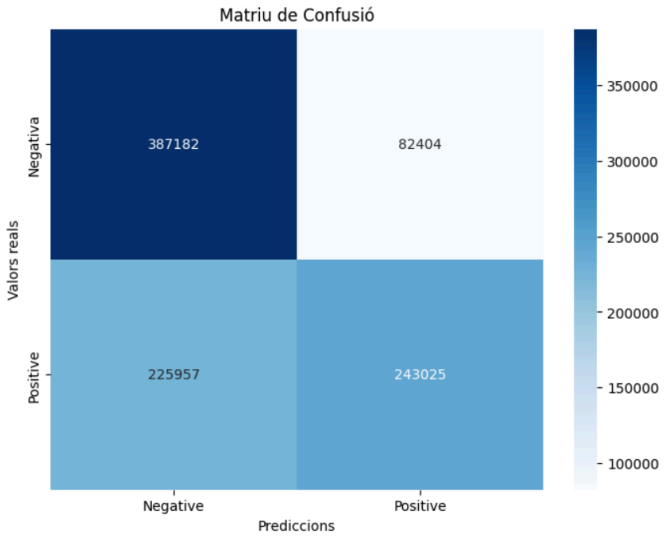



Figura 8: Matriu de confusió 40% train.

### Mètriques

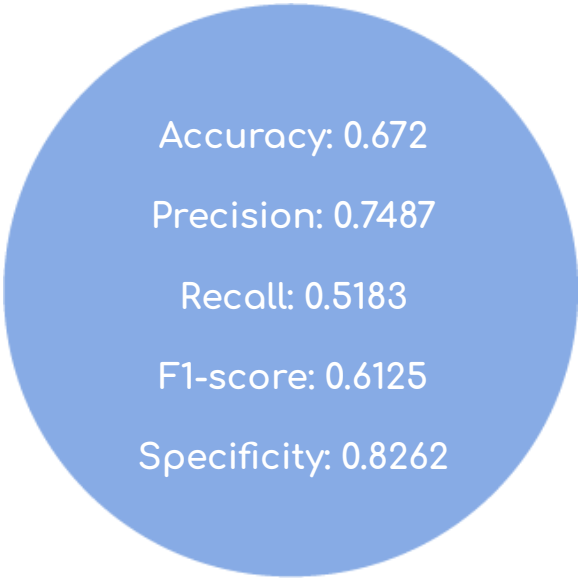



Figura 9: Mètriques 40% train.

- **True Positive (TP):** 243.025
- **False Positive (FP):** 225.957
- **True Negative (TN):** 387.182
- **False Negative (FN):** 82.404

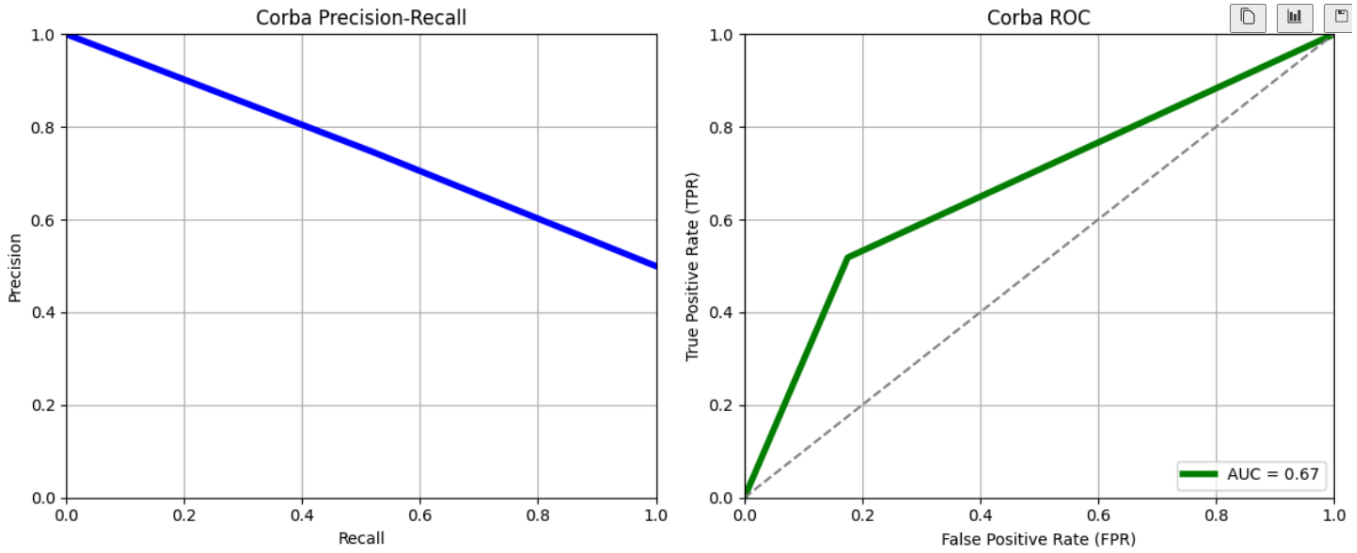



Figura 10: Corbes P-R i ROC 40% train.

## 60% train - 40% test

### Matriu de confusió

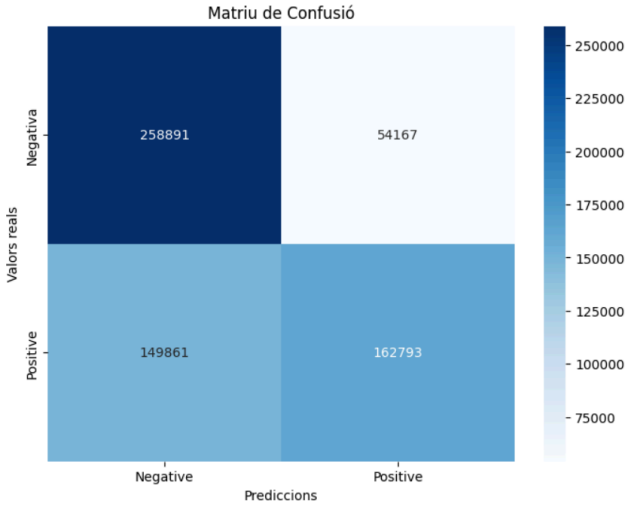



Figura 11: Matriu de confusió 60% train.

### Mètriques

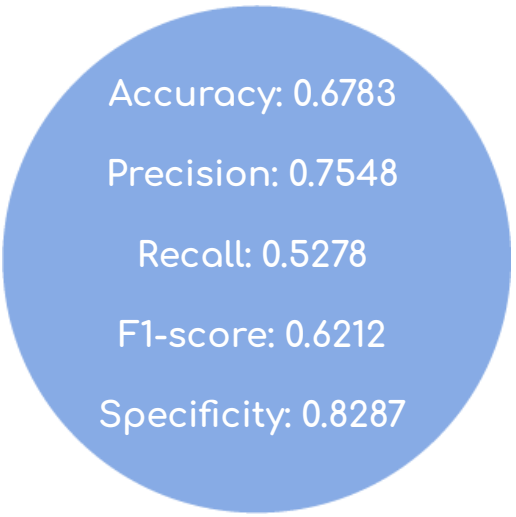



Figura 12: Mètriques 60% train.

- **True Positive (TP):** 162.793
- **False Positive (FP):** 149.861
- **True Negative (TN):** 258.891
- **False Negative (FN):** 54.167

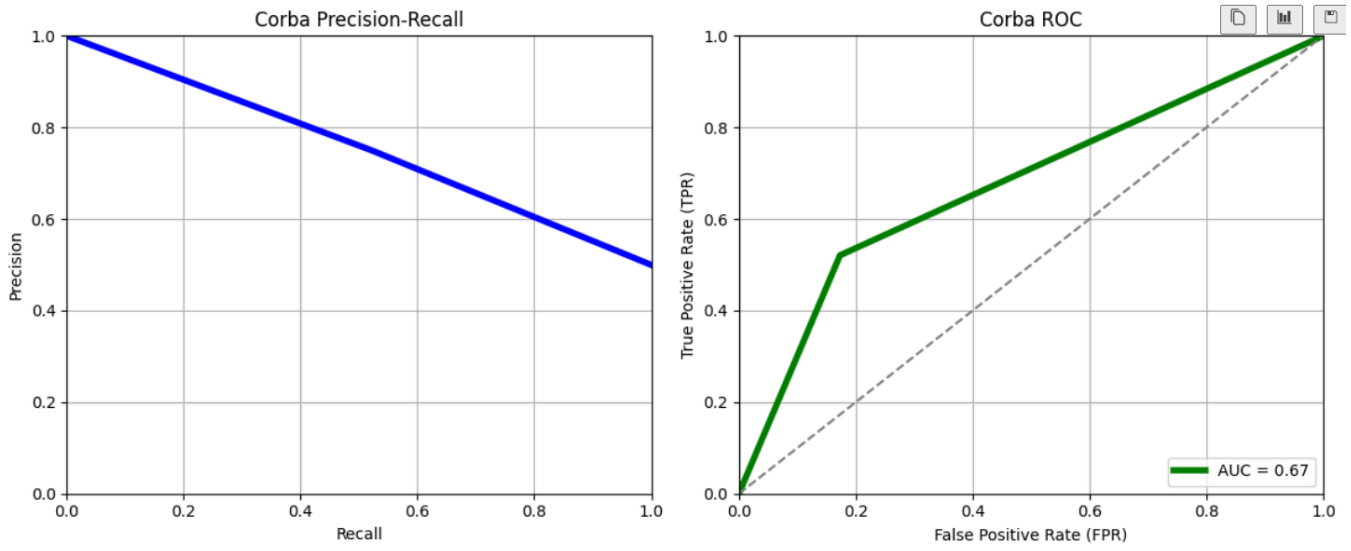



Figura 13: Corbes P-R i ROC 60% train.

## 95% train - 5% test

### Matriu de confusió

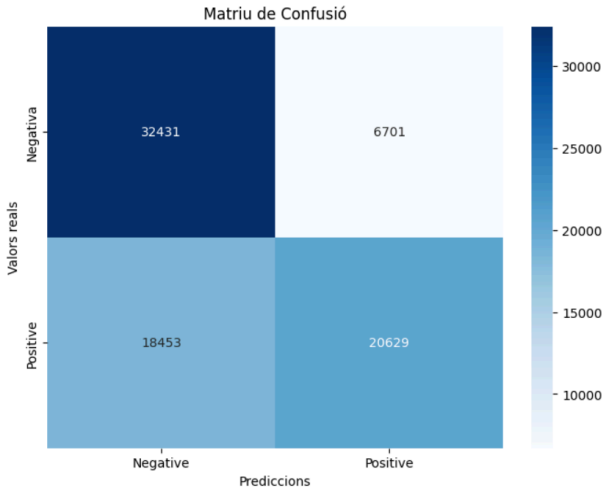



Figura 14: Matriu de confusió 95% train.

### Mètriques

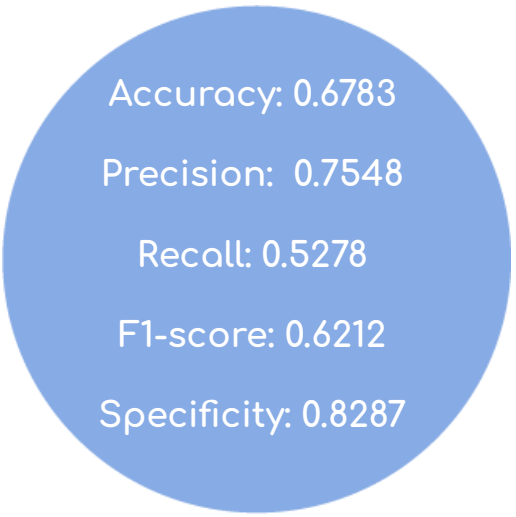



Figura 15: Mètriques 95% train.

- **True Positive (TP):** 20.629
- **False Positive (FP):** 18.453
- **True Negative (TN):** 32.431
- **False Negative (FN):** 6.701

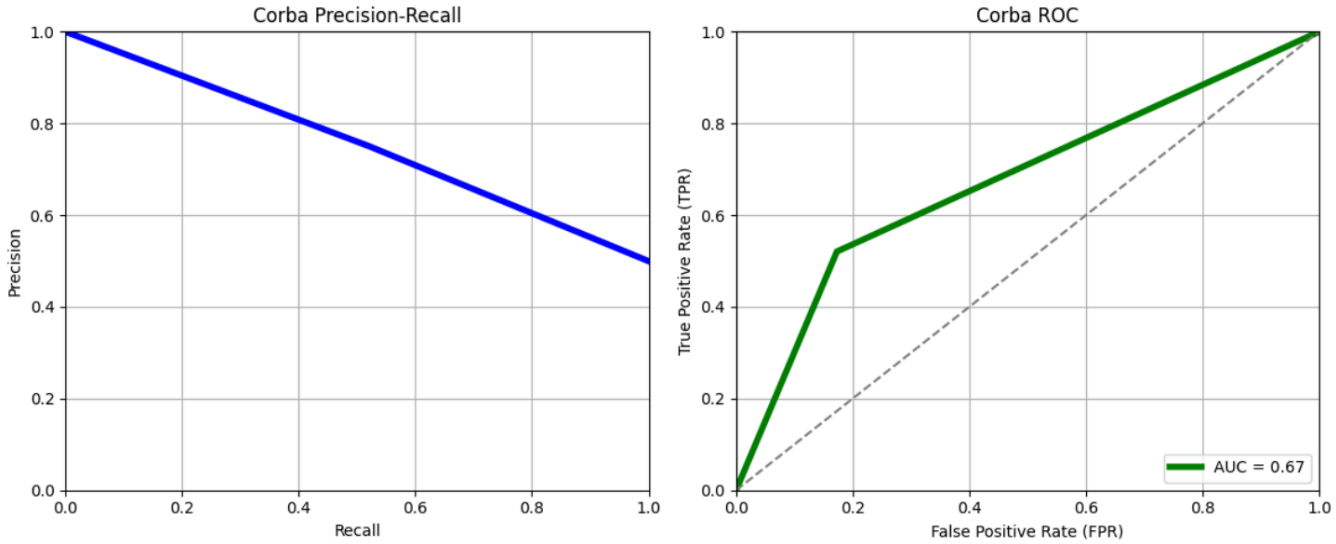



Figura 16: Corbes P-R i ROC 95% train.

## Com afecta la partició de train i test al nostre model?

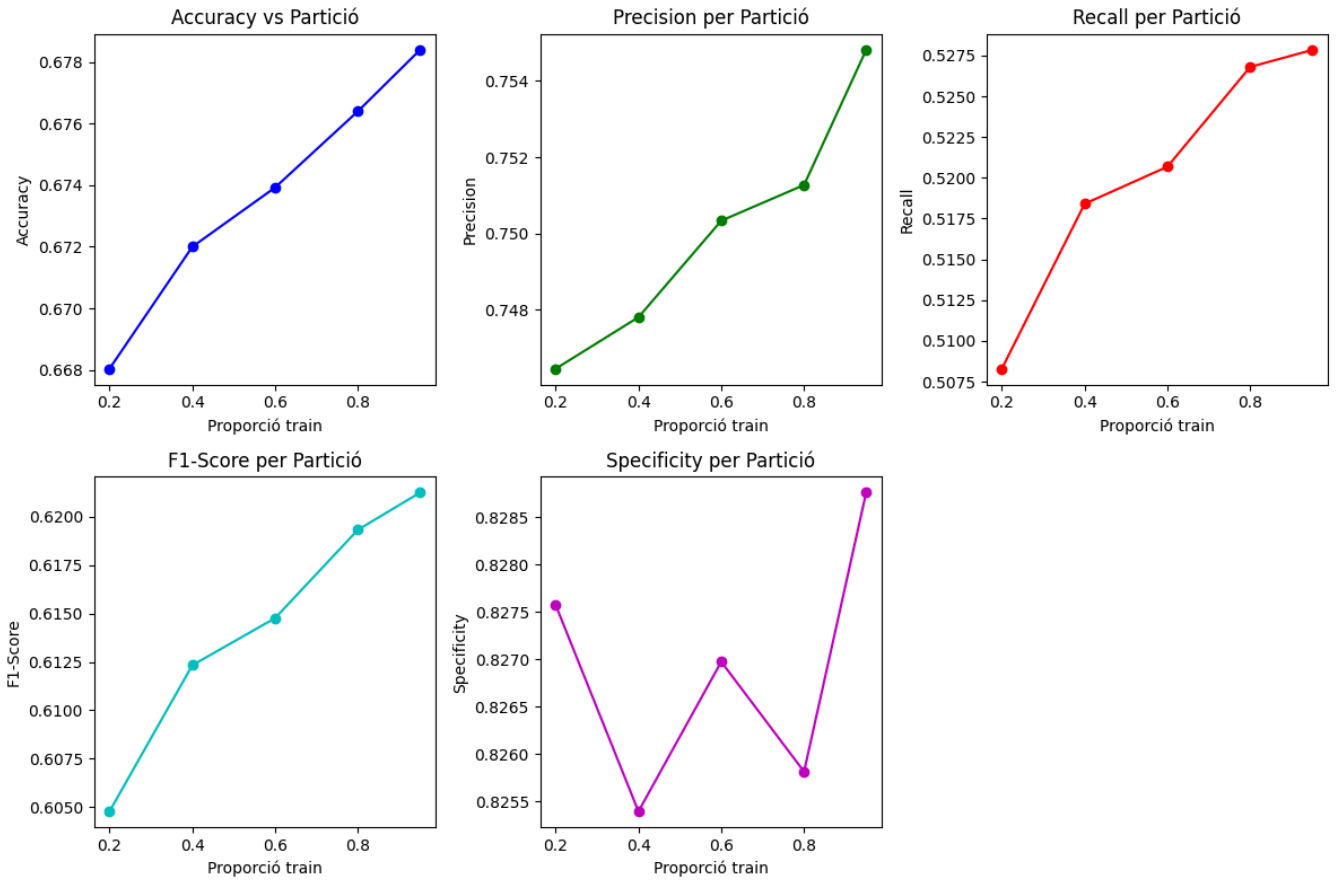



**Figura 17: Mètriques en funció del % de train**

Com es pot observar a les gràfiques de la figura 17, en el nostre cas **no hi ha una variació molt significativa en el rendiment del model en funció de les particions train i test**. El *specificity* es manté practicament igual en tots els casos, i la resta de mètriques augmenten d'una manera força lineal entre 1% i 2% si comparem la partició de train mínima evaluada, un 20%, en contraposició amb la partició de train màxima evaluada d'un 95%.

# 2. Diferents mides de diccionari

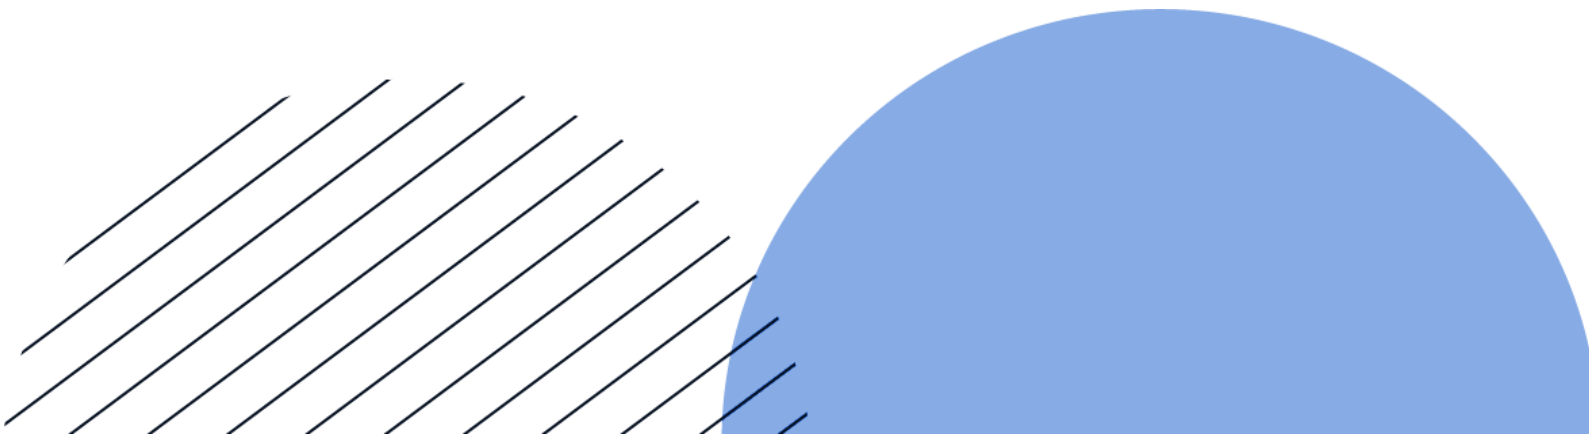
## Resolució

La resolució d'aquest problema ha seguit les següents passes: (les definicions de les passes 1-4 i 7-9 es poden trobar a la secció de l'informe corresponen a la part C)

1. **Lectura de la base de dades**
2. **Preprocessament**
3. **Divisió del dataset en dades de *train* i de *test (80% train - 20% test)***
4. **Generació d'un diccionari**
5. **Determinar mides del diccionari:** S'ha resolt l'obtenció de de les mides de diccionari a evaluar agafant una porció del diccionari original, s'obté un llistat de mides: mida del diccionari original, mida del diccionari original / 2, mida del diccionari original / 3, mida del diccionari original / 4 i mida del diccionari original / 5.

**Per a cada mida de diccionari:**

6. **Obtenir diccionari reduït:** Es genera un diccionari reduït a agafant la quantitat de paraules determinada per la *mida* del diccionari original.
7. **Càlcul de probabilitats**
8. **Fer prediccions a partir de Bayes**
9. **Obtenir mètriques per avaluar el model**



# Anàlisi de resultats

En aquest apartat s'analitzaran les mateixes mètriques que a l'apartat C i B per a cada una de les diferents mides de diccionari que s'han determinat per aquest exercici i es compararan els resultats.

## Mida del diccionari original: 641.158 paraules

### Matriu de confusió

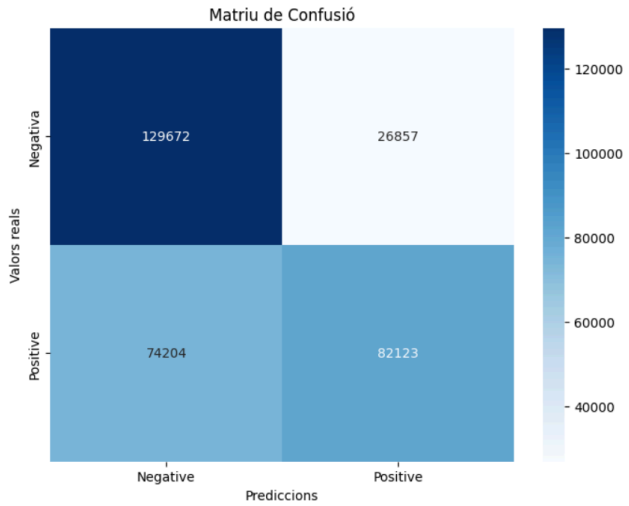



Figura 18: Matriu de confusió amb diccionari de mida original.

- **True Positive (TP):** 82.123
- **False Positive (FP):** 74.204

### Mètriques

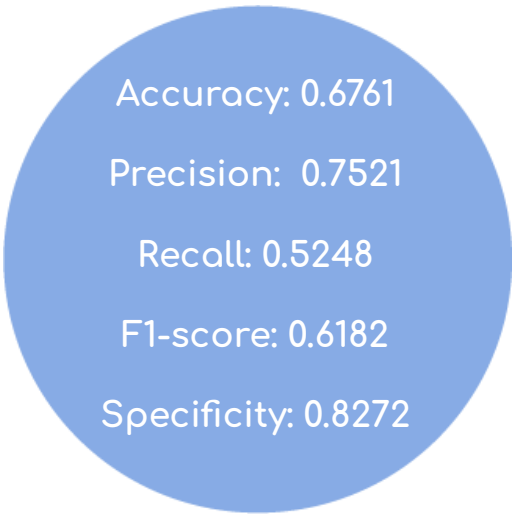



Figura 19: Mètriques amb diccionari de mida original.

- **True Negative (TN):** 129.672
- **False Negative (FN):** 26.857

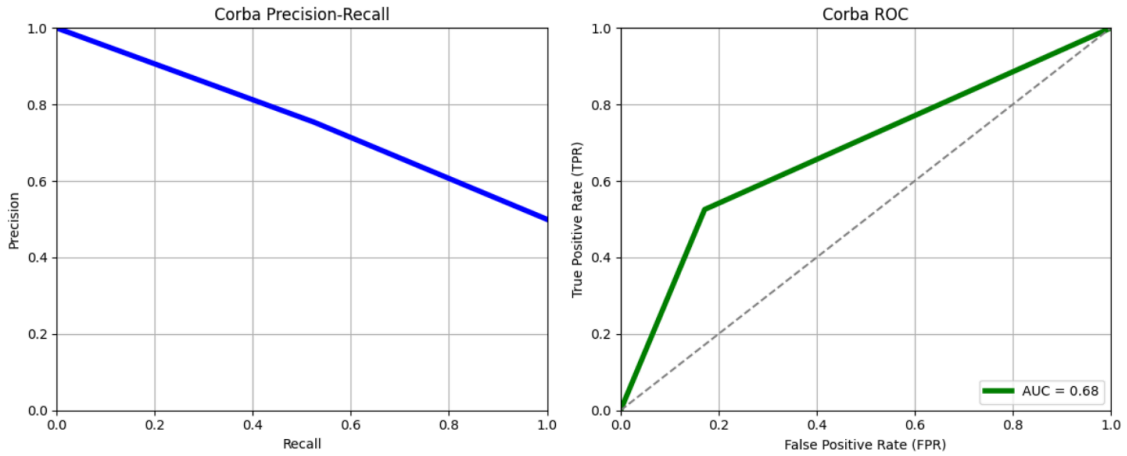



Figura 20: Corbes P-R i ROC amb diccionari de mida original.

## Mida del diccionari: 320.504 paraules

### Matriu de confusió

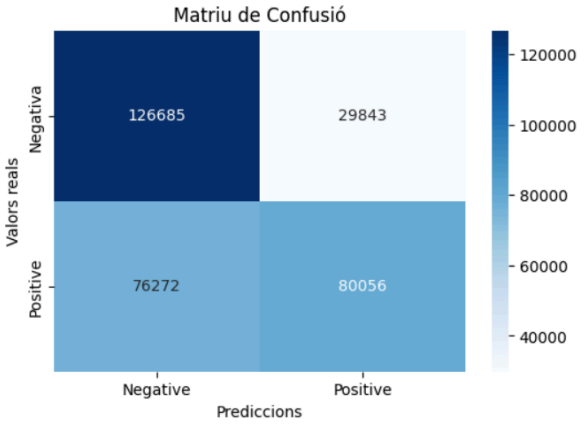



Figura 21: Matriu de confusió amb diccionari de 300k paraules.

### Mètriques

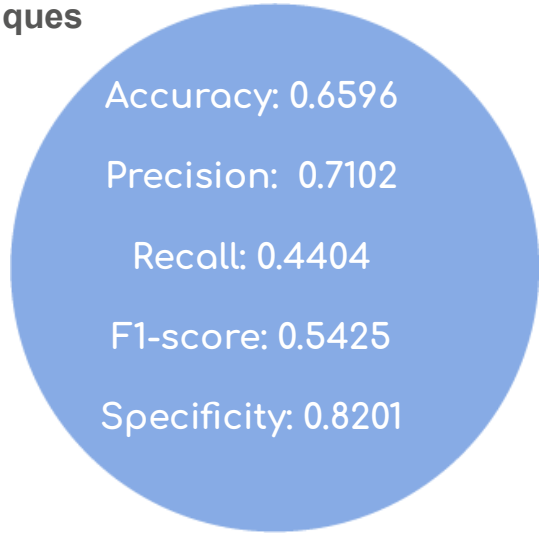



Figura 22: Mètriques amb diccionari de300k paraules.

- **True Positive (TP):** 80.056
- **False Positive (FP):** 76.272
- **True Negative (TN):** 126.685
- **False Negative (FN):** 29.843

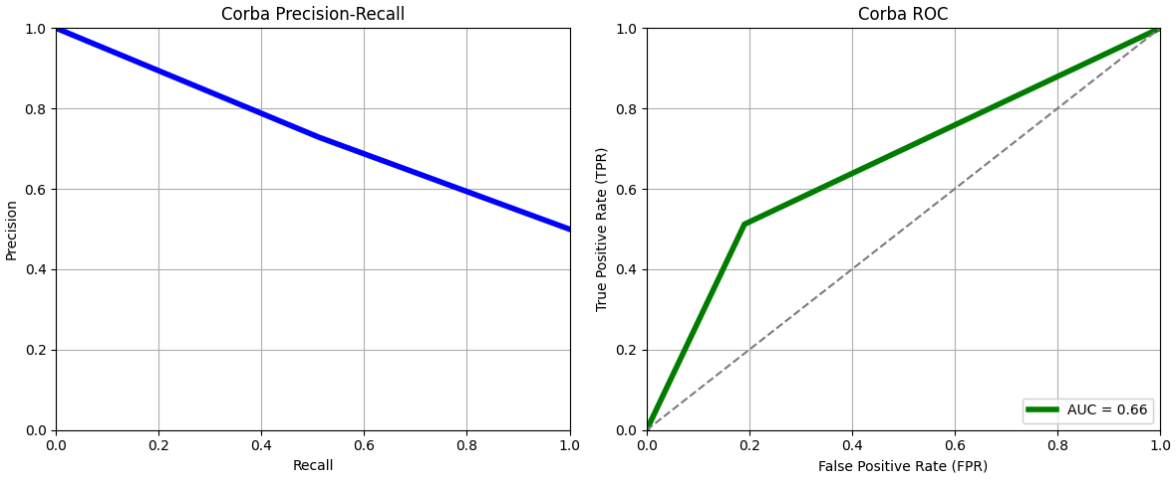



Figura 23: Corbes P-R i ROC amb diccionari de 300k paraules.

## Mida del diccionari: 213.669 paraules

### Matriu de confusió

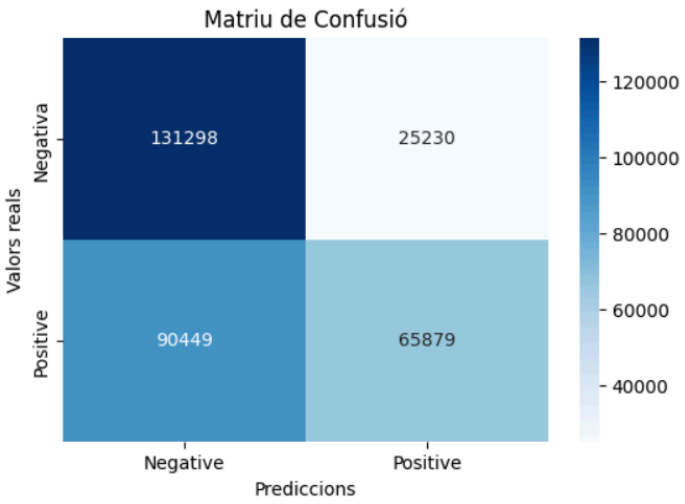



Figura 24: Matriu de confusió amb diccionari de 200k paraules.

### Mètriques

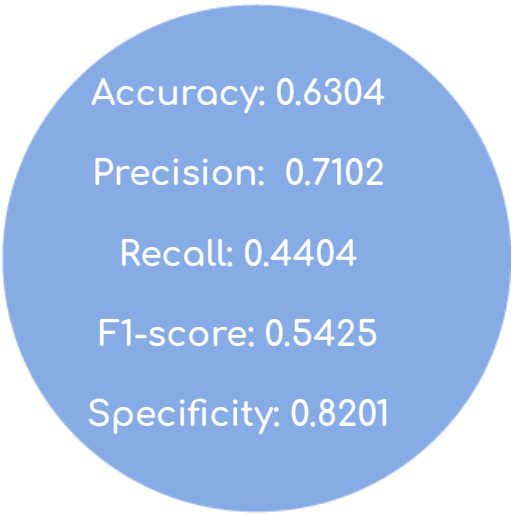



Figura 25: Mètriques amb diccionari de 200k paraules.

- **True Positive (TP):** 65.879
- **False Positive (FP):** 90.449
- **True Negative (TN):** 131.298
- **False Negative (FN):** 25.230

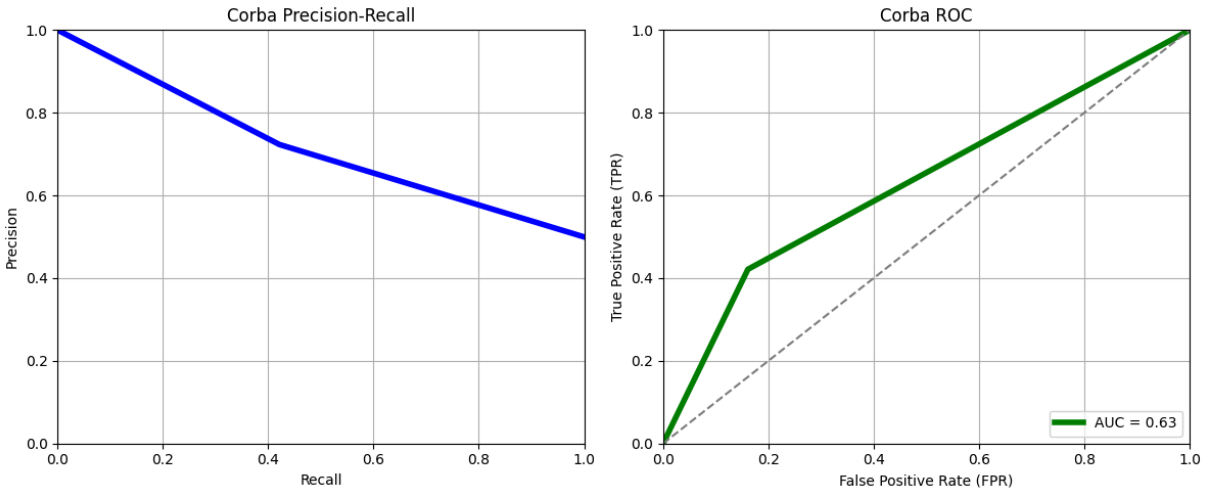



Figura 26: Corbes P-R i ROC amb diccionari de 200k paraules.

## Mida del diccionari: 160.252 paraules

### Matriu de confusió

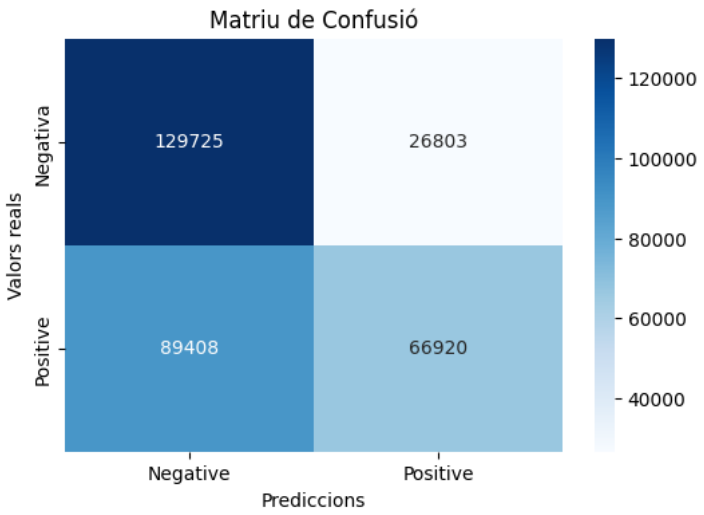



Figura 27: Matriu de confusió amb diccionari de 160k paraules.

### Mètriques

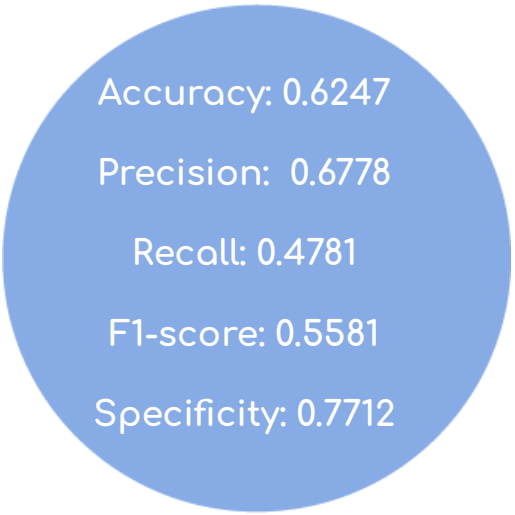



Figura 28: Mètriques amb diccionari de 160k paraules.

- **True Positive (TP):** 66.920
- **False Positive (FP):** 89.408
- **True Negative (TN):** 129.725
- **False Negative (FN):** 26.803

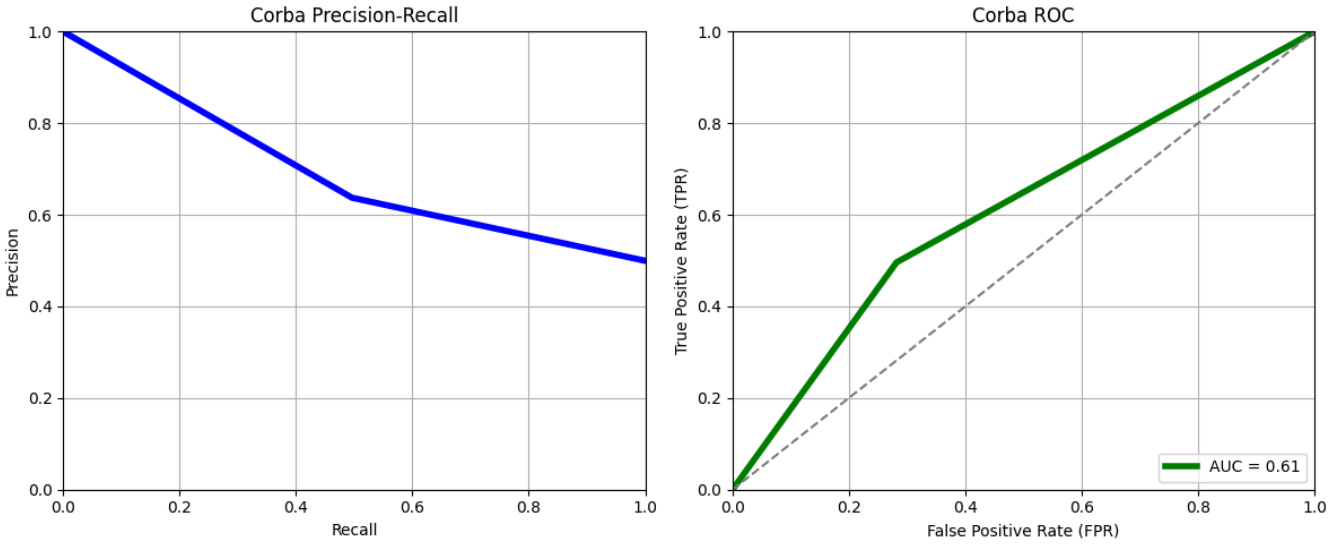



Figura 29: Corbes P-R i ROC amb diccionari de 160k paraules.

## Mida del diccionari: 128.201 paraules

### Matriu de confusió

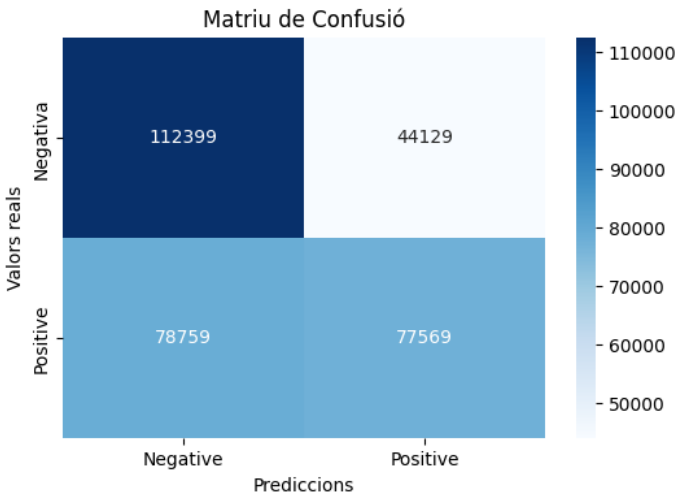



Figura 30: Matriu de confusió amb diccionari de 128k paraules.

### Mètriques

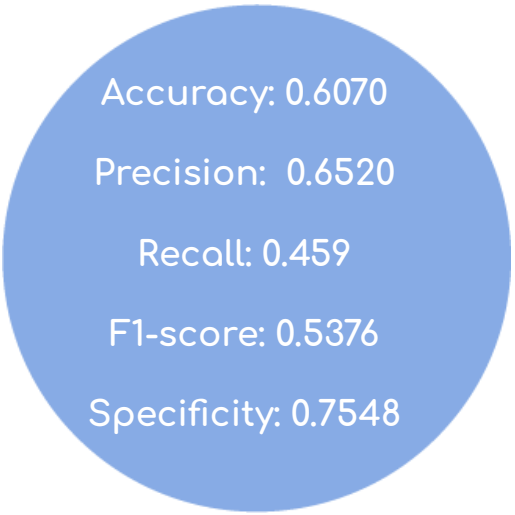



Figura 31: Mètriques amb diccionari de 128k paraules.

- **True Positive (TP):** 77.569
- **False Positive (FP):** 78.759
- **True Negative (TN):** 112.399
- **False Negative (FN):** 44.129

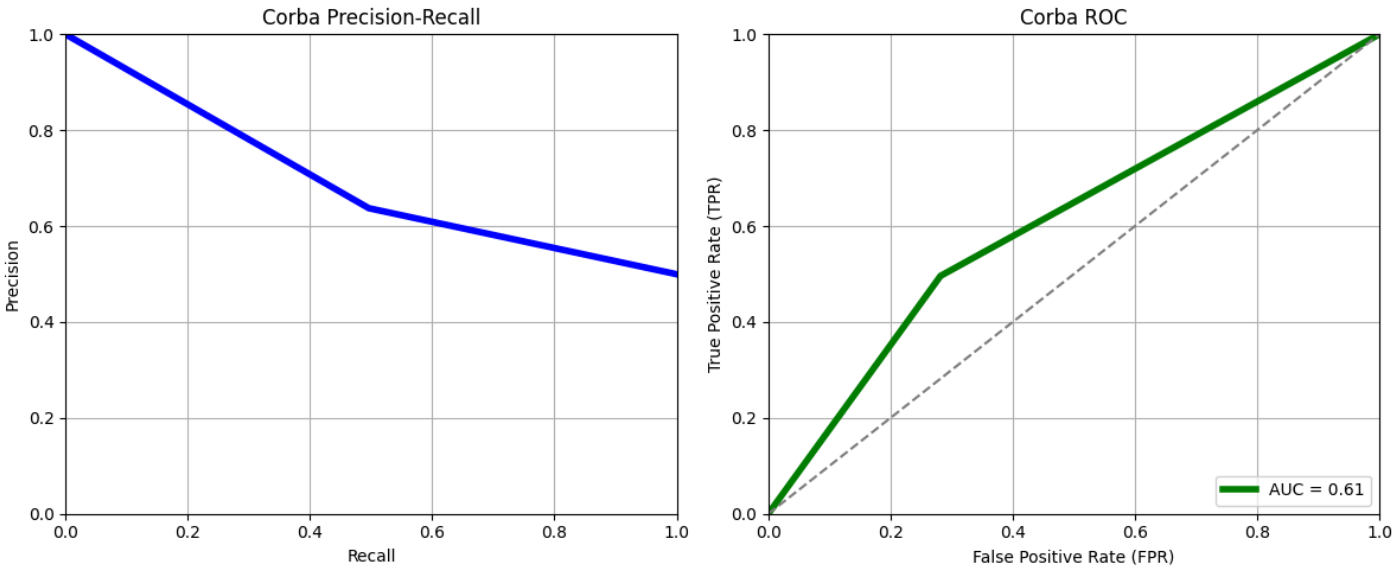



Figura 32: Corbes P-R i ROC amb diccionari de 128k paraules.

## Com afecta la mida del diccionari al rendiment del nostre model?

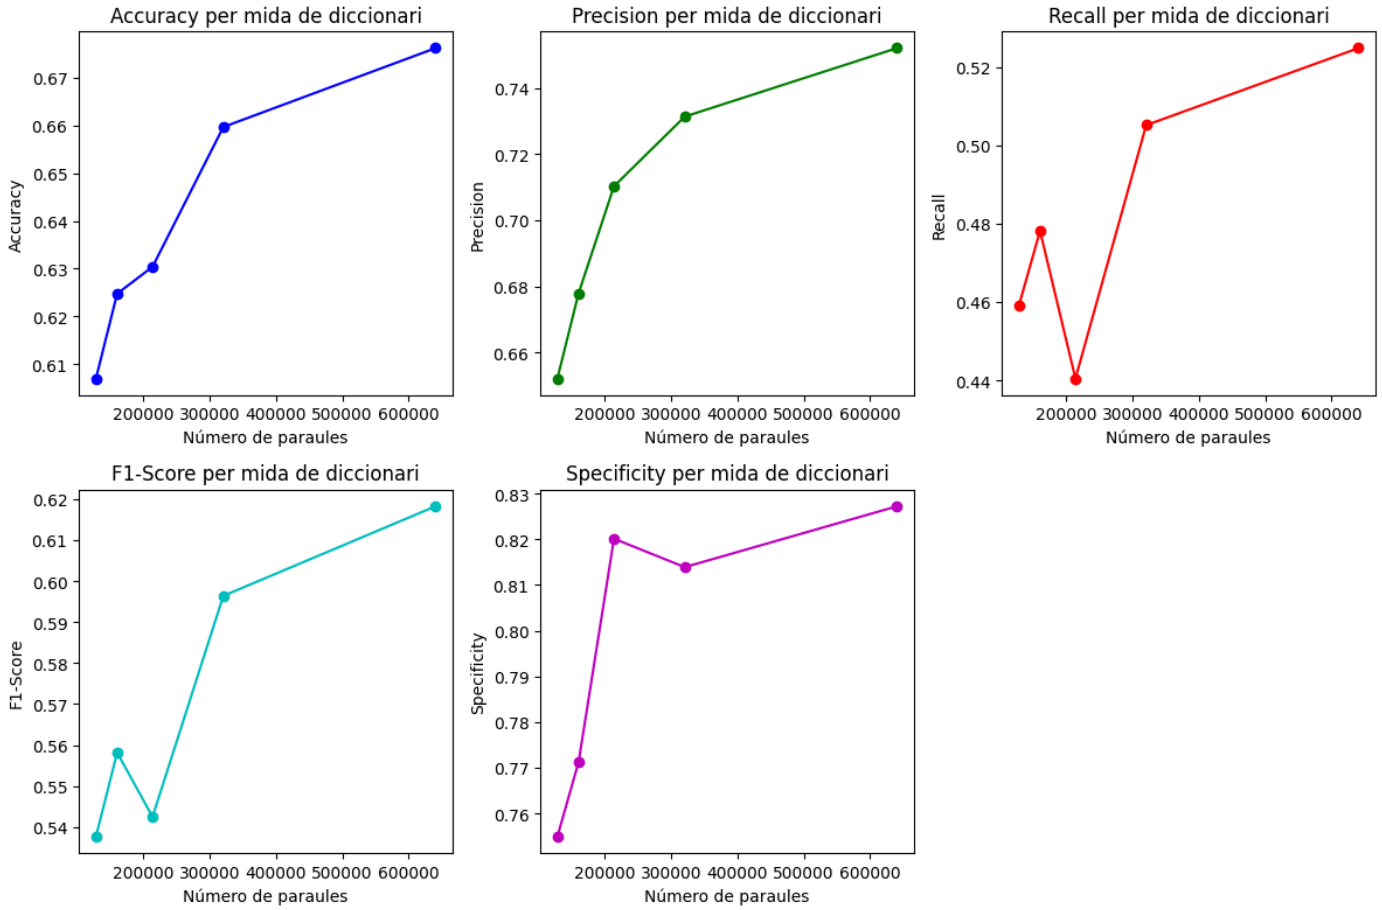



**Figura 33: Mètriques en funció de la mida del diccionari**

Com es pot observar a les gràfiques de la figura 33, la mida del diccionari sí afecta de manera considerable al rendiment del model. Podem observar per totes les mètriques, una diferència de al voltant del 8-10% en funció de si fem servir el diccionari més petit o el més gran, sent la disminució del rendiment més pronunciada quan el diccionari baixi de 300k paraules. Vist això, podem afirmar que **la mida del diccionari és determinant pel bon funcionament del model.**

# 3. Mida de diccionari fixe, diferents conjunts de train.

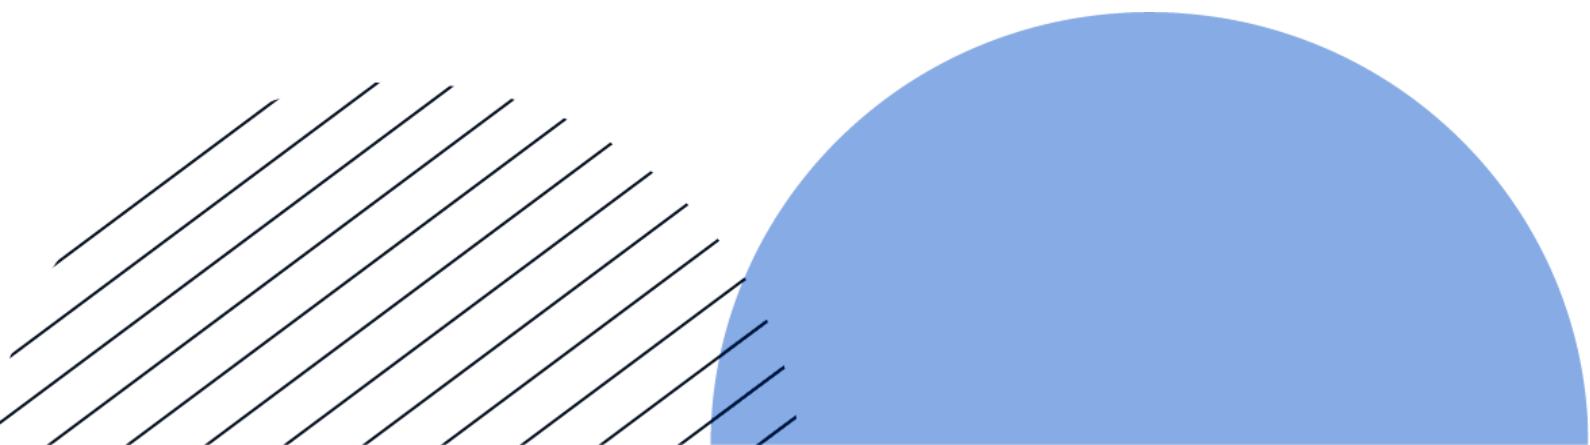
## Resolució

La resolució d'aquest problema ha seguit les següents passes: (les definicions de les passes 1-3 i 5-10 es poden trobar a la secció de l'informe corresponen a la part C i als apartats anteriors de la part B)

1. **Lectura de la base de dades**
2. **Preprocessament**
3. **Determinar les particions de train i test**
4. **Determinar mida del diccionari:** Determinem la mida fixe que tindran els diccionaris generats a partir del conjunt de train. He decidit que la mida sigui 200.000 paraules perquè es troba per sota de la mida del diccionari que es genera a partir del conjunt de train amb la partició més petita.

**Per a cada partició:**

5. **Divisió del dataset en dades de *train* i de *test (partició% train - (1-partició)% test)***
6. **Generació d'un diccionari**
7. **Obtenir diccionari reduït a partir del diccionari original**
8. **Càlcul de probabilitats**
9. **Fer prediccions a partir de Bayes**
10. **Obtenir mètriques per avaluar el model**



# Anàlisi de resultats

En aquest apartat comprovarem l'efecte que té la partició de train i test en el model de predicció si determinem una mida fixe pel diccionari amb anterioritat. Farem servir les mètriques i gràfiques que ja hem utilitzat als apartats anteriors.

## 20% train - 80% test

### Matriu de confusió

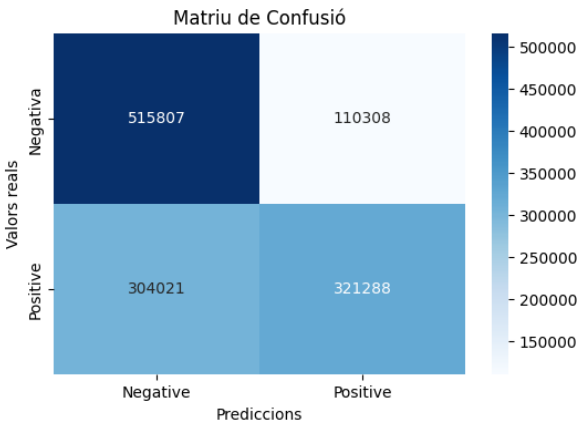



Figura 34: Matriu de confusió amb diccionari fixe i 20% de train.

- **True Positive (TP):** 321.288
- **False Positive (FP):** 304.021

### Mètriques

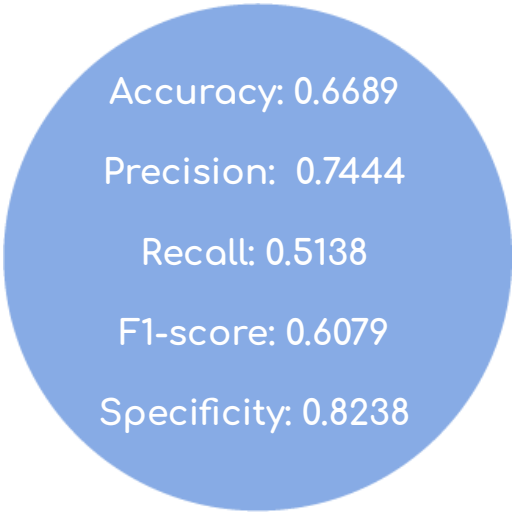



Figura 35: Mètriques amb diccionari fixe i 20% de train.

- **True Negative (TN):** 515.807
- **False Negative (FN):** 110.308

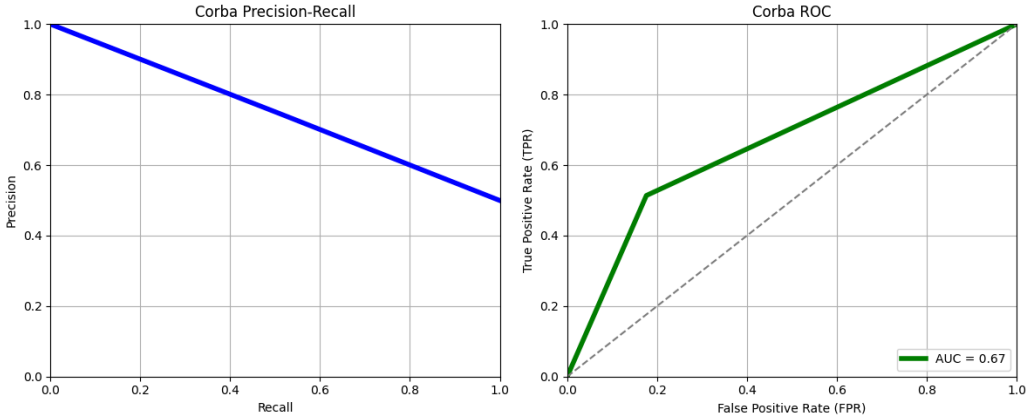
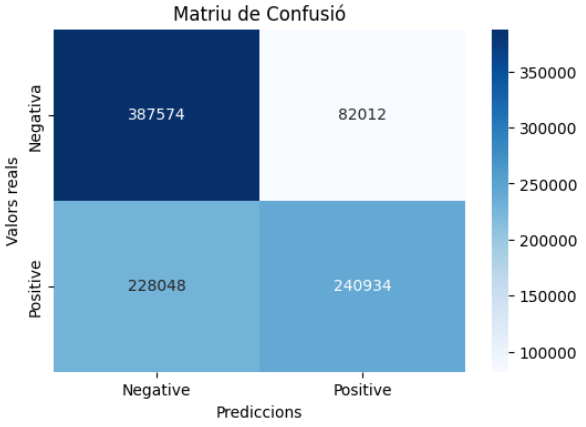



Figura 36: Corbes P-R i ROC amb diccionari fixe i 20% de train.

## 40% train - 60% test

### Matriu de confusió




### Mètriques

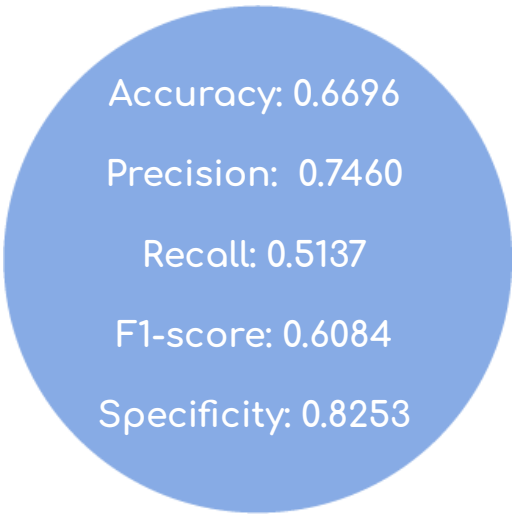



**Figura 37: Matriu de confusió amb diccionari fixe i 40% de train.**

**Figura 38: Mètriques amb diccionari fixe i 40% de train.**

- **True Positive (TP):** 240.934
- **False Positive (FP):** 228.048
- **True Negative (TN):** 387.574
- **False Negative (FN):** 82.012

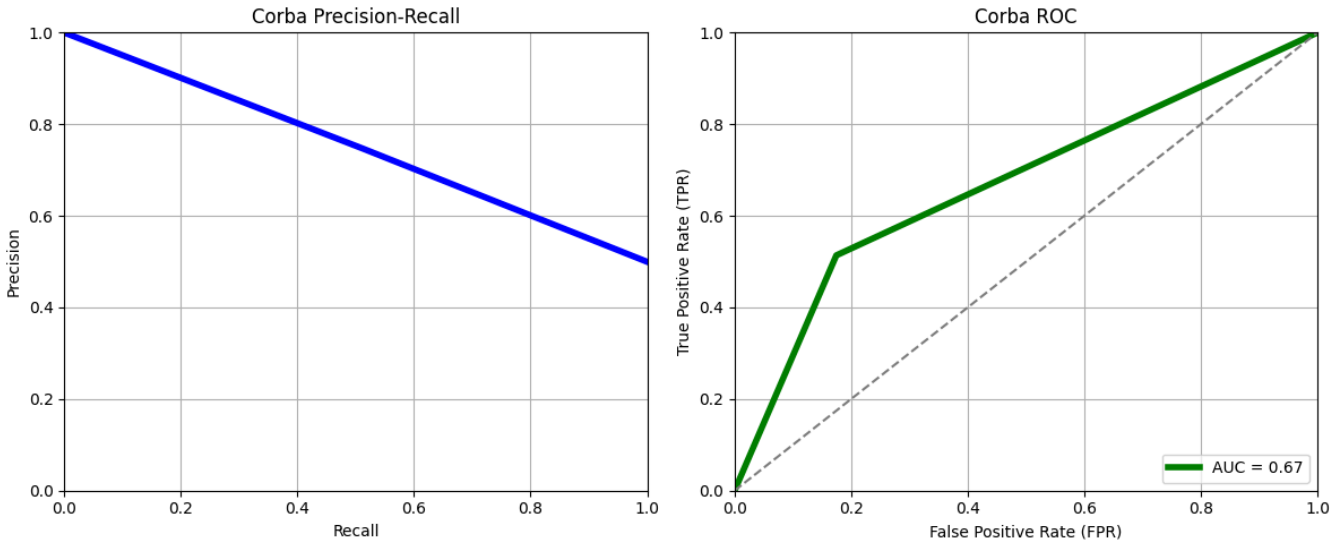
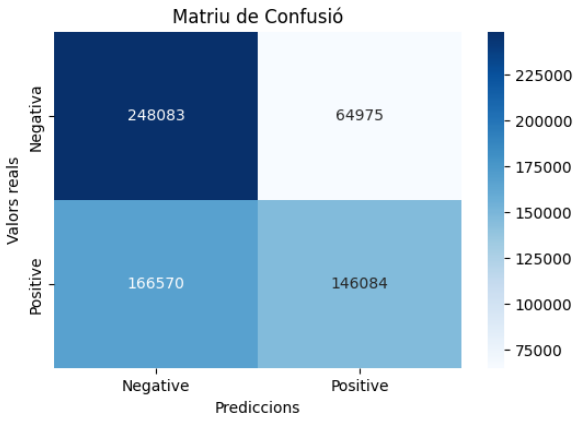



**Figura 39: Corbes P-R i ROC amb diccionari fixe i 40% de train.**

## 60% train - 40% test

### Matriu de confusió




### Mètriques

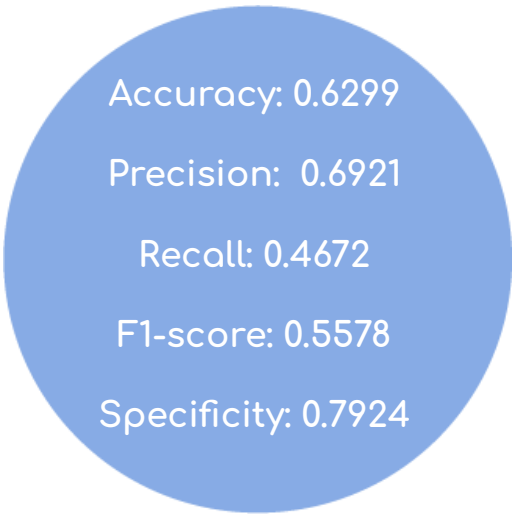



**Figura 40: Matriu de confusió amb diccionari fixe i 60% de train.**

**Figura 41: Mètriques amb diccionari fixe i 60% de train.**

- **True Positive (TP):** 146.084
- **False Positive (FP):** 166.570
- **True Negative (TN):** 248.083
- **False Negative (FN):** 64.975

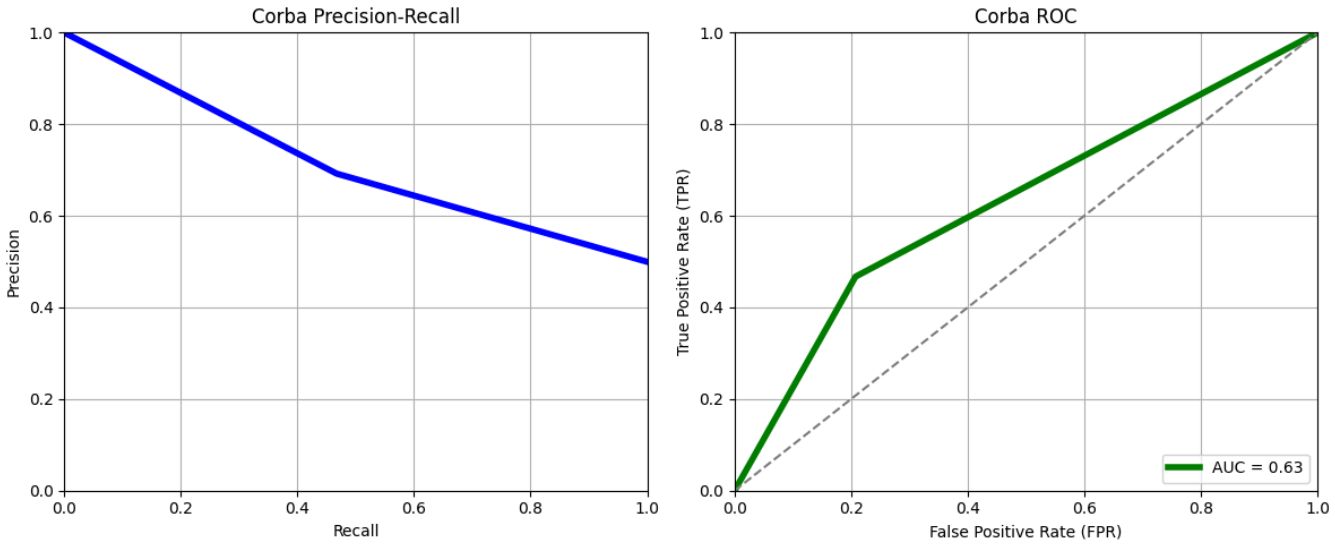



**Figura 42: Corbes P-R i ROC amb diccionari fixe i 60% de train.**

## 80% train - 20% test

### Matriu de confusió

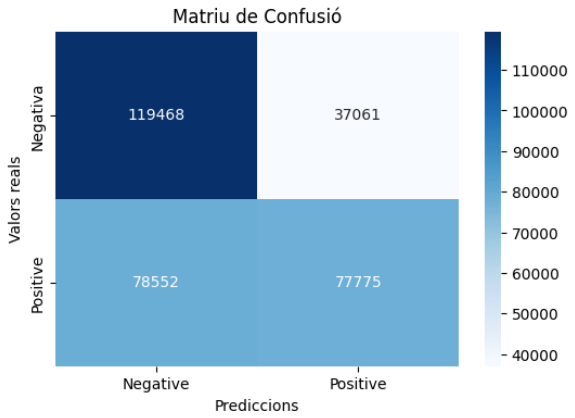



Figura 43: Matriu de confusió amb diccionari fixe i 80% de train.

### Mètriques

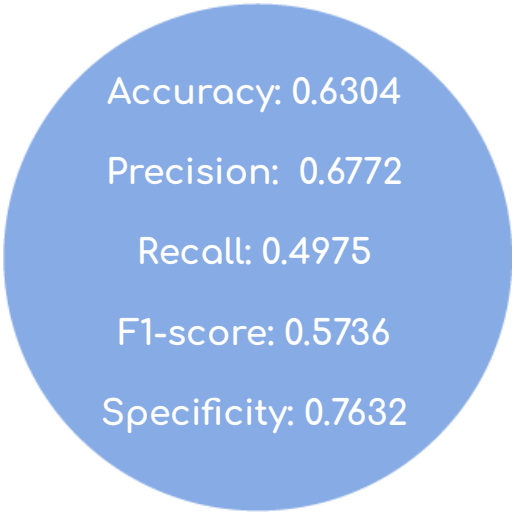



Figura 44: Mètriques amb diccionari fixe i 80% de train.

- **True Positive (TP):** 77.775
- **False Positive (FP):** 78.552
- **True Negative (TN):** 119.468
- **False Negative (FN):** 37.061

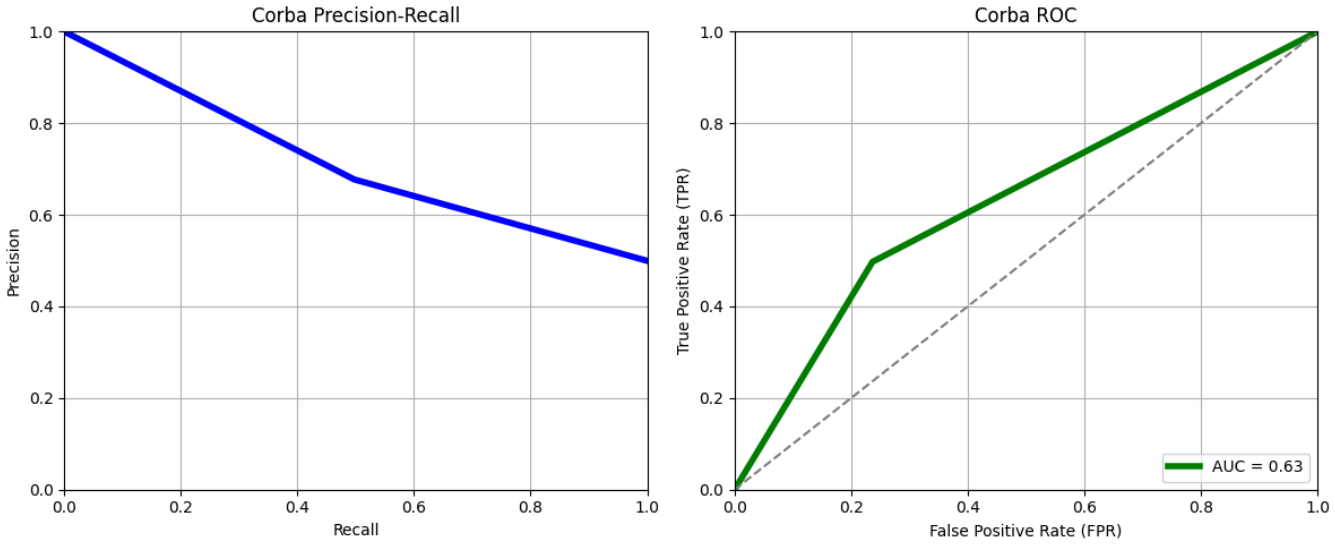



Figura 45: Corbes P-R i ROC amb diccionari fixe i 80% de train.

## 95% train - 5% test

### Matriu de confusió

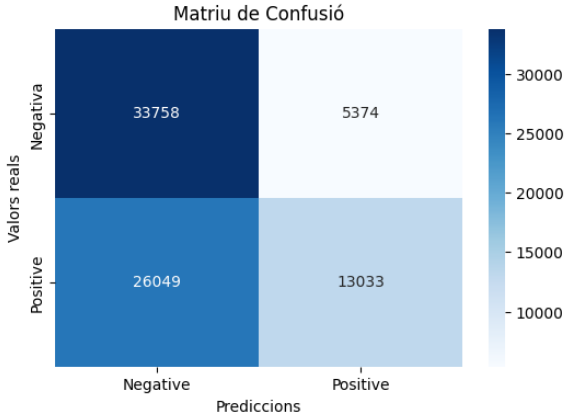



Figura 46: Matriu de confusió amb diccionari fixe i 95% de train.

### Mètriques

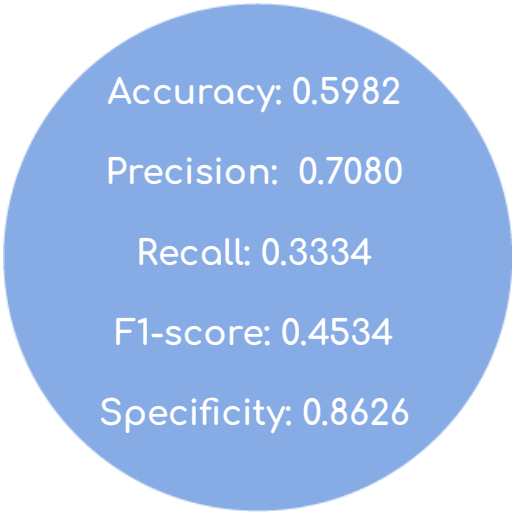



Figura 47: Mètriques amb diccionari fixe i 95% de train.

- **True Positive (TP):** 12.033
- **False Positive (FP):** 26.049
- **True Negative (TN):** 33.758
- **False Negative (FN):** 5.374

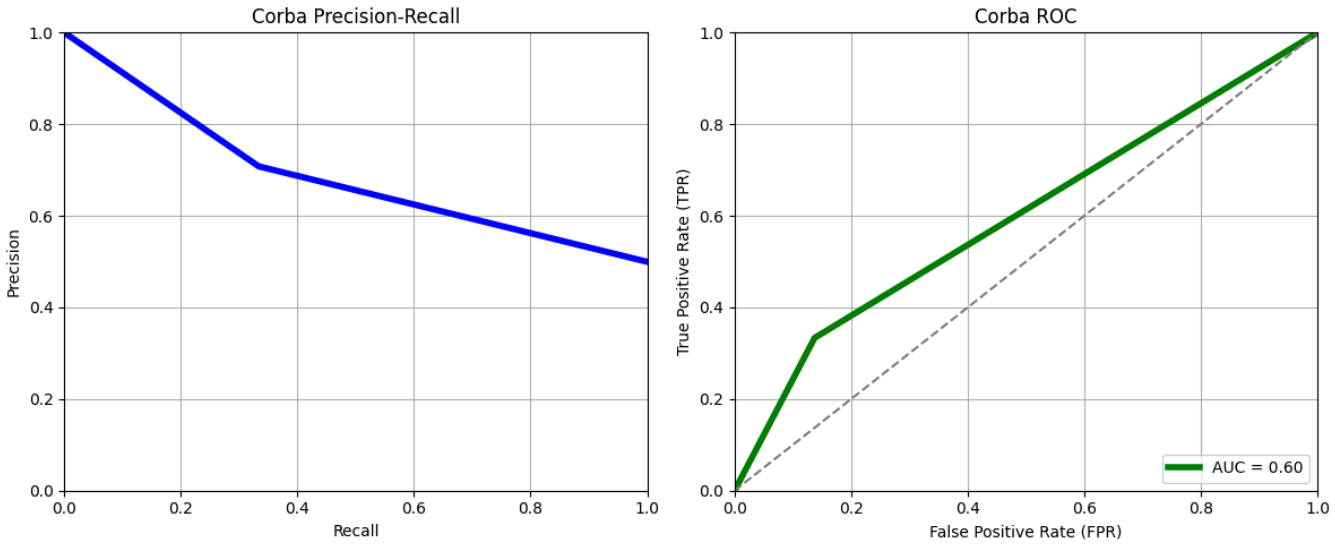



Figura 48: Corbes P-R i ROC amb diccionari fixe i 95% de train.

**Com afecta la partició de train i test al nostre model si fem servir una mida de diccionari fixe?**

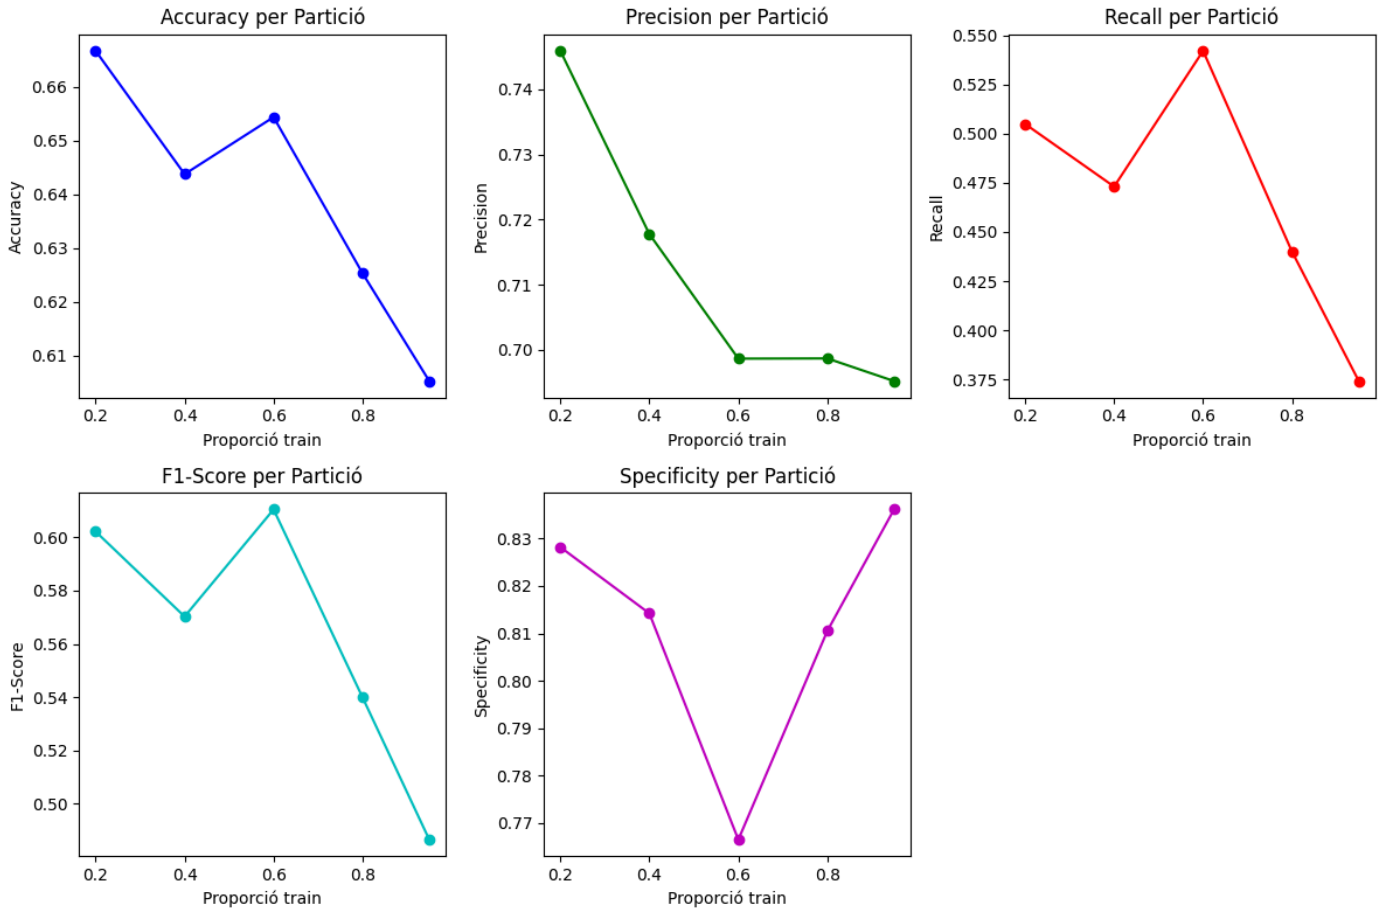



**Figura 49: Mètriques en funció de les particions *train-test*, amb una mida de diccionari fixe**

Com es pot observar a la figura 49, i després d'haver realitzat vàries proves, podem afirmar que el model tendeix a rendir pitjor a mesura que augmenta el conjunt de train i la mida del diccionari és fixe. Això es pot deure a que pels conjunts de train més petits fem sevir una part més gran del diccionari generat a partir d'aquest conjunt, mentre que per conjunts de train més grans només agafem una petita porció del diccionari. És més possible que es perdin paraules rellevants si retallem el diccionari del conjunt de train més gran perquè perdem moltes més paraules pel camí que amb el conjunt més petit.

## Preguntes

1. **. Què passa en el primer cas, quan es va ampliant el nombre de tweets i el diccionari per fer el train?**

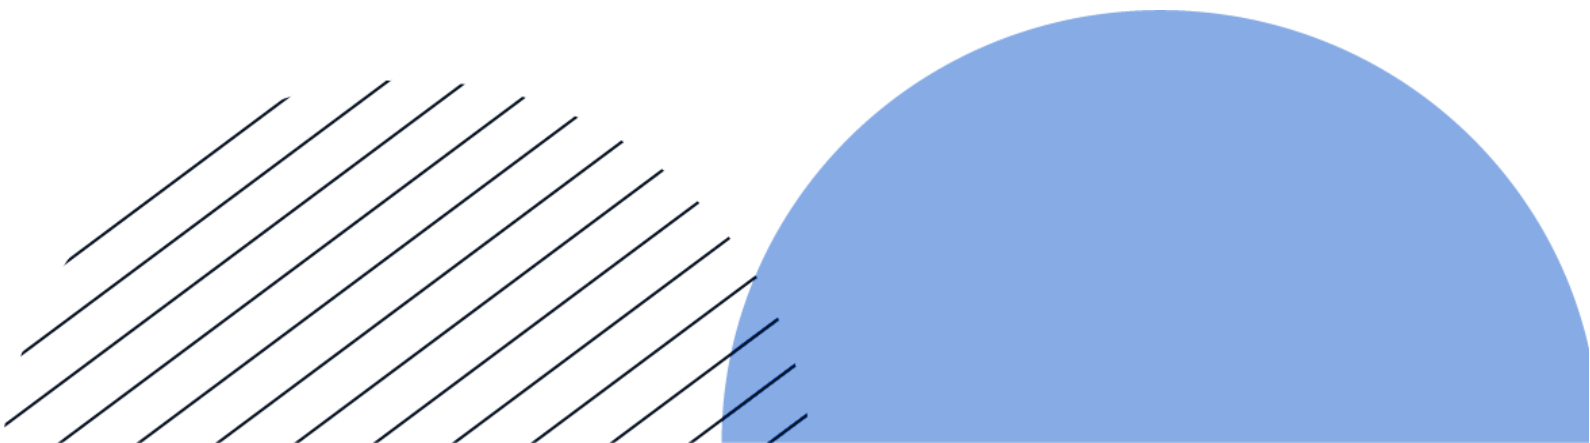
L'ampliació del nombre de tweets i el diccionari per fer el test no comporta canvis molt significatius. Existeix millora a mesura que el conjunt de train augmenta, però no suposa més d'un 1% o 2% de millora total a les mètriques analitzades entre la configuració amb el conjunt de train més petit i amb conjunt de train més gran.

2. **Com afecta la mida del diccionari?**

La mida del diccionari és determinant pel bon funcionament del model. La majoria de mètriques analitzades milloren entre un 8% i un 10% si es fa servir el diccionari de mida màxima enlloc del diccionari de mida mínima.

3. **Com afecta la mida del conjunt de tweets de test?**

El model tendeix a rendir pitjor a mesura que augmenta el conjunt de train i la mida del diccionari és fixe per les raons explicades amb anterioritat.



# PART A

## Enunciat

En aquest exercici es demana **repetir els anàlisis fets a la part B però fent servir *Laplace Smoothing*.** El suavitzat de Laplace és una tècnica molt útil, especialment per evitar el problema de les probabilitats zero quan es treballa amb dades que tenen combinacions d'esdeveniments mai observats durant l'entrenament.

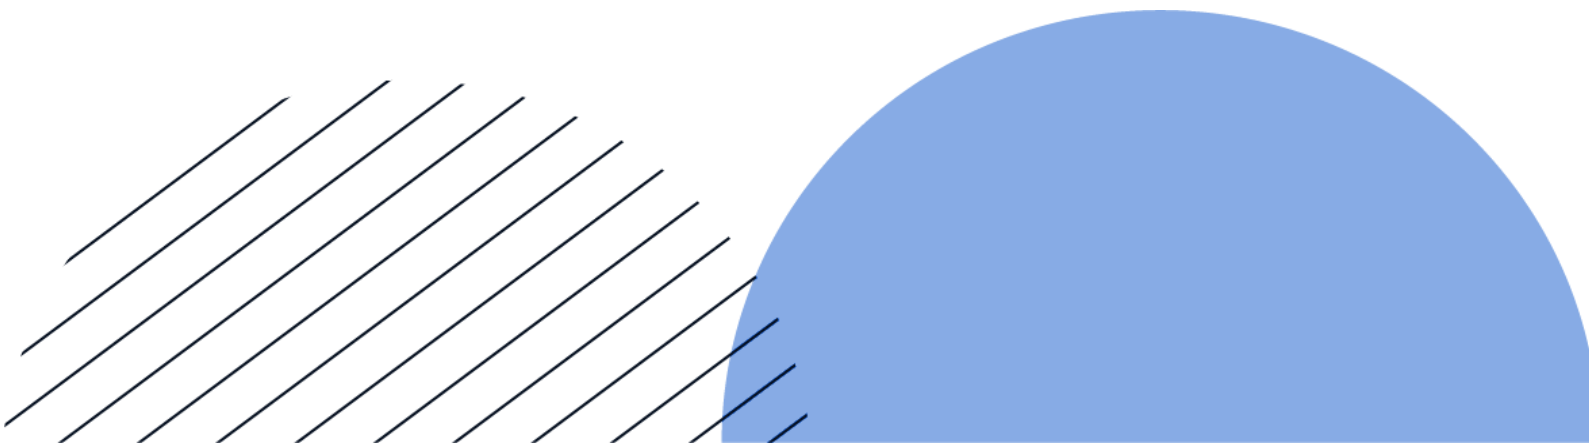
## Resolució

La resolució és la mateixa per a cadascun dels tres apartats de la part B, amb la diferència que s'aplica el suavitzat de Laplace en el càlcul de probabilitats utilitzant Bayes.

En el meu cas, reutilitzo totes les funcions que he implementat en els apartats anteriors, però els passo un booleà anomenat Laplace amb el seu valor establert a True, que indica que el càlcul de probabilitats s'ha de realitzar aplicant el suavitzat de Laplace.

## Anàlisi de resultats

Per analitzar els resultats, ens centrarem únicament en comparar els valors obtinguts a les mètriques a cada un dels apartats de la part B en comparació amb els obtinguts fent servir *Laplace Smoothing* pels mateixos problemes.



# 1. Ampliar el conjunt de train

### 20% train - 80% test

| SENSE LAPLACE SMOOTHING | AMB LAPLACE SMOOTHING |
|---|---|
| Accuracy: 0.668 | Accuracy: 0.7421 |
| Precision: 0.7464 | Precision: 0.8574 |
| Recall: 0.5082 | Recall: 0.5804 |
| F1-score: 0.6047 | F1-Score: 0.6922 |
| Specificity: 0.8275 | Specificity: 0.9036 |

Taula 1.1: Comparació de mètriques a la part B apartat 1 en funció de si es fa servir o no Laplace Smoothing

### 40% train - 60% test

| SENSE LAPLACE SMOOTHING | AMB LAPLACE SMOOTHING |
|---|---|
| Accuracy: 0.672 | Accuracy: 0.7470 |
| Precision: 0.7487 | Precision: 0.8581 |
| Recall: 0.5183 | Recall: 0.5914 |
| F1-score: 0.6125 | F1-Score: 0.7002 |
| Specificity: 0.8262 | Specificity: 0.9023 |

Taula 1.2: Comparació de mètriques a la part B apartat 1 en funció de si es fa servir o no Laplace Smoothing

### 60% train - 40% test

| SENSE LAPLACE SMOOTHING | AMB LAPLACE SMOOTHING |
|---|---|
| Accuracy: 0.6783 | Accuracy: 0.7496 |
| Precision: 0.7548 | Precision: 0.8591 |
| Recall: 0.5278 | Recall: 0.5967 |
| F1-score: 0.6212 | F1-Score: 0.7043 |
| Specificity: 0.8287 | Specificity: 0.9023 |

Taula 1.3: Comparació de mètriques a la part B apartat 1 en funció de si es fa servir o no Laplace Smoothing

### 80% train - 20% test

| SENSE LAPLACE SMOOTHING | AMB LAPLACE SMOOTHING |
|---|---|
| Accuracy: 0.6769 | Accuracy: 0.7501 |
| Precision: 0.7535 | Precision: 0.8596 |
| Recall: 0.5253 | Recall: 0.5975 |
| F1-score: 0.619 | F1-Score: 0.7050 |
| Specificity: 0.8284 | Specificity: 0.9025 |

Taula 1.4: Comparació de mètriques a la part B apartat 1 en funció de si es fa servir o no Laplace Smoothing

### 95% train - 5% test

| SENSE LAPLACE SMOOTHING | AMB LAPLACE SMOOTHING |
|---|---|
| Accuracy: 0.6783 | Accuracy: 0.7506 |
| Precision: 0.7548 | Precision: 0.8599 |
| Recall: 0.5278 | Recall: 0.5983 |
| F1-score: 0.6212 | F1-Score: 0.7056 |
| Specificity: 0.8287 | Specificity: 0.9026 |

**Taula 1.5: Comparació de mètriques a la part B apartat 1 en funció de si es fa servir o no Laplace Smoothing**

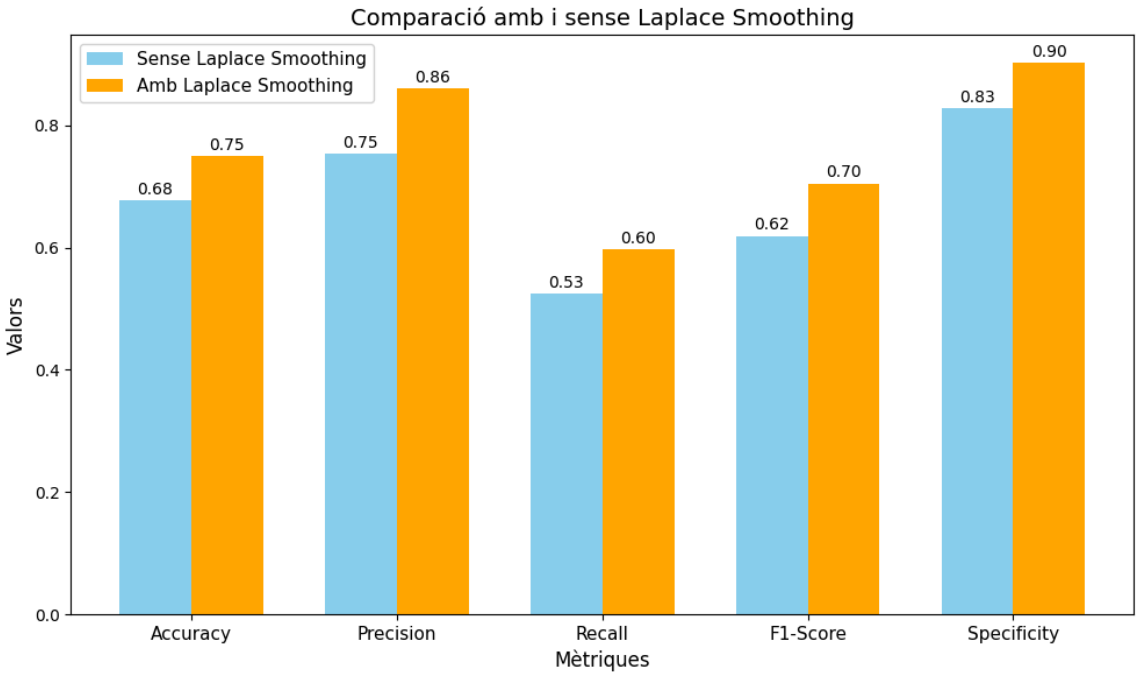



**Figura 50: Comparació de mètriques en funció de si es fa servir o no Laplace Smoothing per a una divisió de 80% train i 20% test.**

Com es pot veure a la figura 50, **l'ús del Suavitzat de Laplace resulta en una millora considerable a totes les mètriques avaluades** a la part B apartat 1. Les millores ronden al voltant del 7-10%.

# 2. Diferents mides de diccionari

### Mida del diccionari: 641.000 paraules

| SENSE LAPLACE SMOOTHING | AMB LAPLACE SMOOTHING |
|---|---|
| Accuracy: 0.6761 | Accuracy: 0.7511 |
| Precision: 0.7521 | Precision: 0.8599 |
| Recall: 0.5248 | Recall: 0.5996 |
| F1-score: 0.6182 | F1-Score: 0.7066 |
| Specificity: 0.8272 | Specificity: 0.9024 |

Taula 2.1: Comparació de mètriques a la part B apartat 2 en funció de si es fa servir o no Laplace Smoothing

### Mida del diccionari: 320.000 paraules

| SENSE LAPLACE SMOOTHING | AMB LAPLACE SMOOTHING |
|---|---|
| Accuracy: 0.6596 | Accuracy: 0.6887 |
| Precision: 0.7102 | Precision: 0.7732 |
| Recall: 0.4404 | Recall: 0.5368 |
| F1-score: 0.5425 | F1-Score: 0.6313 |
| Specificity: 0.8201 | Specificity: 0.8405 |

Taula 2.2: Comparació de mètriques a la part B apartat 2 en funció de si es fa servir o no Laplace Smoothing

### Mida del diccionari: 213.000 paraules

| SENSE LAPLACE SMOOTHING | AMB LAPLACE SMOOTHING |
|---|---|
| Accuracy: 0.6304 | Accuracy: 0.6547 |
| Precision: 0.7102 | Precision: 0.7206 |
| Recall: 0.4404 | Recall: 0.5127 |
| F1-score: 0.5425 | F1-Score: 0.5946 |
| Specificity: 0.8201 | Specificity: 0.7964 |

Taula 2.3: Comparació de mètriques a la part B apartat 2 en funció de si es fa servir o no Laplace Smoothing

### Mida del diccionari: 160.000 paraules

| SENSE LAPLACE SMOOTHING | AMB LAPLACE SMOOTHING |
|---|---|
| Accuracy: 0.6247 | Accuracy: 0.6372 |
| Precision: 0.6778 | Precision: 0.7096 |
| Recall: 0.4781 | Recall: 0.4736 |
| F1-score: 0.5581 | F1-Score: 0.5637 |
| Specificity: 0.7712 | Specificity: 0.8007 |

Taula 2.4: Comparació de mètriques a la part B apartat 2 en funció de si es fa servir o no Laplace Smoothing

### Mida del diccionari: 128.000 paraules

| SENSE LAPLACE SMOOTHING | AMB LAPLACE SMOOTHING |
|---|---|
| Accuracy: 0.6070 | Accuracy: 0.6109 |
| Precision: 0.6520 | Precision: 0.6736 |
| Recall: 0.459 | Recall: 0.4316 |
| F1-score: 0.5376 | F1-Score: 0.5252 |
| Specificity: 0.7548 | Specificity: 0.7900 |

**Taula 2.5: Comparació de mètriques a la part B apartat 2 en funció de si es fa servir o no Laplace Smoothing**

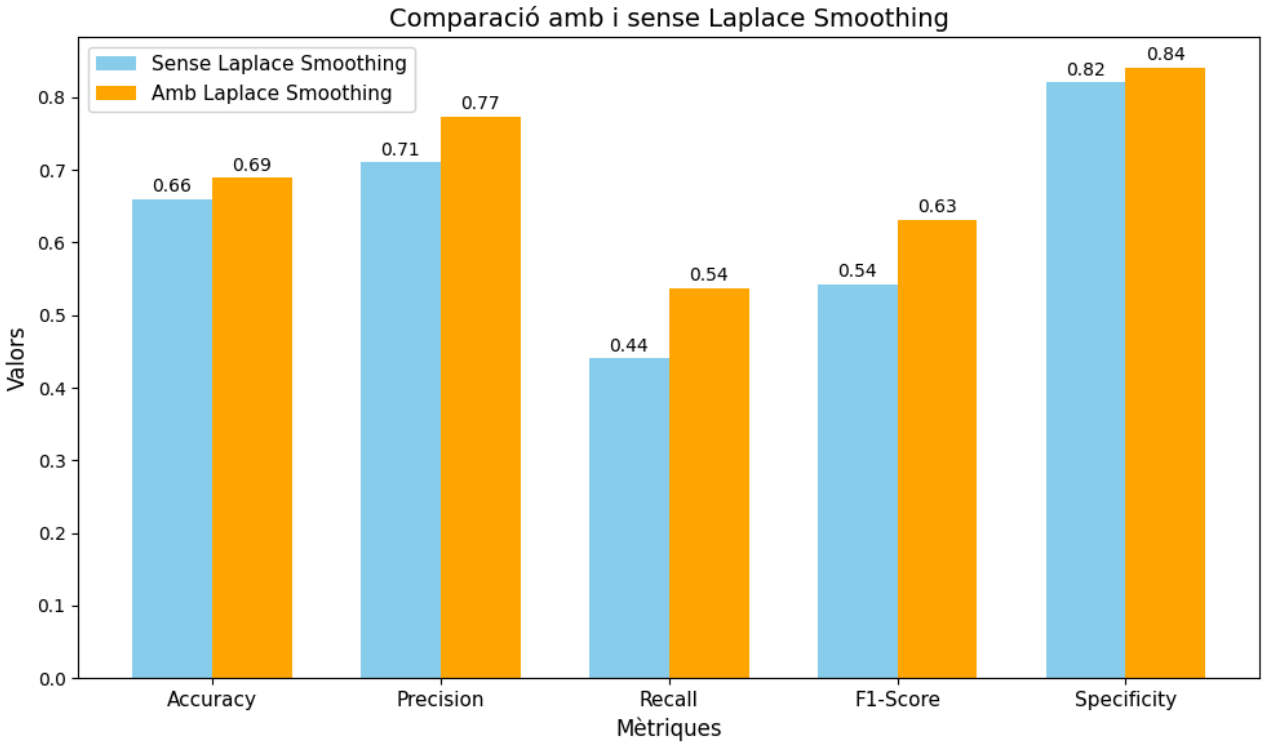



**Figura 51: Comparació de mètriques en funció de si es fa servir o no Laplace Smoothing per a una divisió de 80% train i 20% test i un diccionari de 320.000 paraules.**

En aquest apartat el *Laplace Smoothing* també **millora el rendiment del model**, amb pujades a les mètriques avaluades de fins al 10%.

# 3. Mida de diccionari fixe, diferents conjunts de train.

### 20% train - 80% test. Diccionari de 200.000 paraules

| SENSE LAPLACE SMOOTHING | AMB LAPLACE SMOOTHING |
|---|---|
| Accuracy: 0.6689 | Accuracy: 0.7393 |
| Precision: 0.7444 | Precision: 0.8412 |
| Recall: 0.5138 | Recall: 0.5896 |
| F1-score: 0.6079 | F1-Score: 0.6933 |
| Specificity: 0.8238 | Specificity: 0.8888 |

Taula 3.1: Comparació de mètriques a la part B apartat 3 en funció de si es fa servir o no Laplace Smoothing

### 40% train - 60% test. Diccionari de 200.000 paraules

| SENSE LAPLACE SMOOTHING | AMB LAPLACE SMOOTHING |
|---|---|
| Accuracy: 0.6696 | Accuracy: 0.6856 |
| Precision: 0.7460 | Precision: 0.7637 |
| Recall: 0.5137 | Recall: 0.5369 |
| F1-score: 0.6084 | F1-Score: 0.6305 |
| Specificity: 0.8253 | Specificity: 0.8340 |

Taula 3.2: Comparació de mètriques a la part B apartat 3 en funció de si es fa servir o no Laplace Smoothing

### 60% train - 40% test. Diccionari de 200.000 paraules

| SENSE LAPLACE SMOOTHING | AMB LAPLACE SMOOTHING |
|---|---|
| Accuracy: 0.6299 | Accuracy: 0.6726 |
| Precision: 0.6921 | Precision: 0.7315 |
| Recall: 0.4672 | Recall: 0.5447 |
| F1-score: 0.5578 | F1-Score: 0.6244 |
| Specificity: 0.7924 | Specificity: 0.8003 |

Taula 3.3: Comparació de mètriques a la part B apartat 3 en funció de si es fa servir o no Laplace Smoothing

### 80% train - 20% test. Diccionari de 200.000 paraules

| SENSE LAPLACE SMOOTHING | AMB LAPLACE SMOOTHING |
|---|---|
| Accuracy: 0.6304 | Accuracy: 0.6717 |
| Precision: 0.6772 | Precision: 0.7000 |
| Recall: 0.4975 | Recall: 0.6004 |
| F1-score: 0.5736 | F1-Score: 0.6464 |
| Specificity: 0.7632 | Specificity: 0.7430 |

Taula 3.4: Comparació de mètriques a la part B apartat 3 en funció de si es fa servir o no Laplace Smoothing

### 95% train - 5% test. Diccionari de 200.000 paraules

| SENSE LAPLACE SMOOTHING | AMB LAPLACE SMOOTHING |
|---|---|
| Accuracy: 0.5982 | Accuracy: 0.6345 |
| Precision: 0.7080 | Precision: 0.7391 |
| Recall: 0.3334 | Recall: 0.4149 |
| F1-score: 0.4534 | F1-Score: 0.5315 |
| Specificity: 0.8626 | Specificity: 0.8537 |

**Taula 3.5: Comparació de mètriques a la part B apartat 3 en funció de si es fa servir o no Laplace Smoothing**

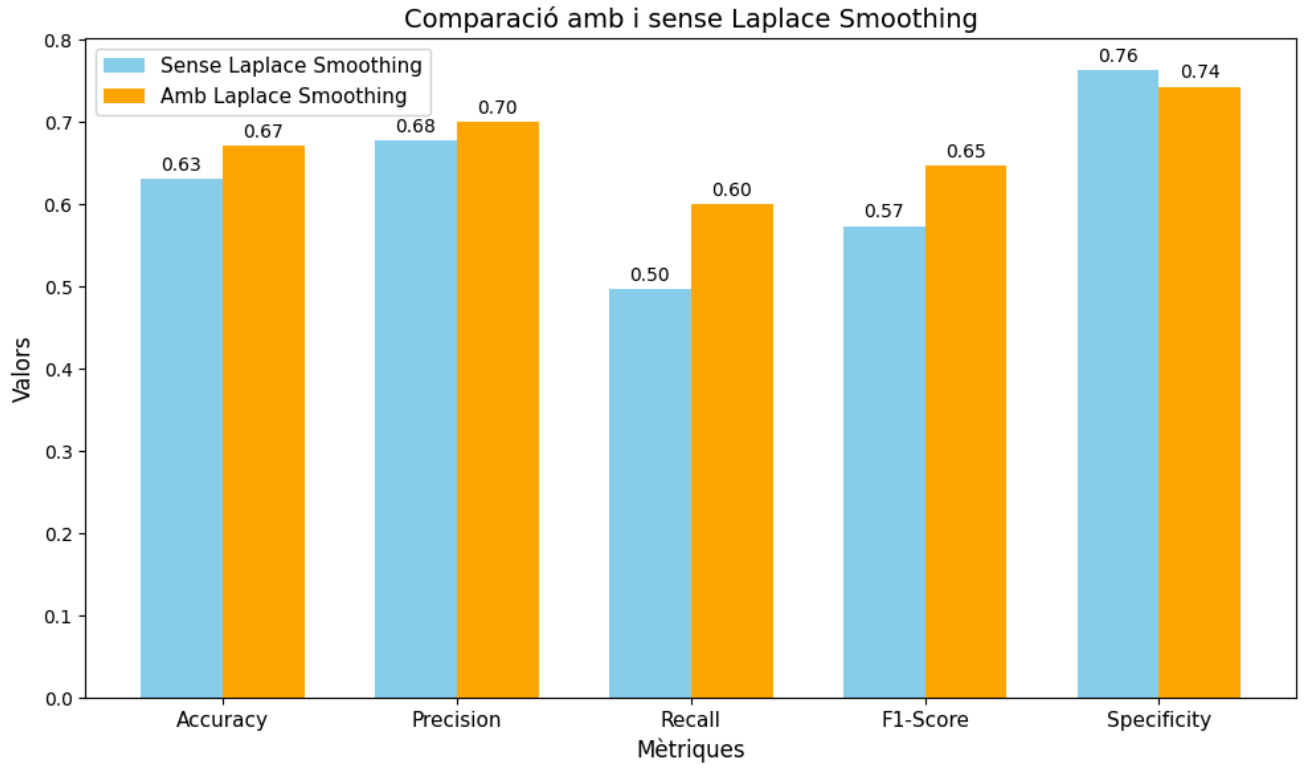



**Figura 52: Comparació de mètriques en funció de si es fa servir o no Laplace Smoothing per a una divisió de 80% train i 20% test i un diccionari de 200.000 paraules.**

Novament, el Laplace Smoothing, de manera general, també **millora el rendiment del model en aquest apartat**. Aquesta millora és especialment significativa en el **recall** i, conseqüentment, en el F1-score. Per tant, el Suavitzat de Laplace ajuda el model a **identificar amb més precisió els casos positius**.

# CONCLUSIONS

Del model de predicció realitzat trec les següents conclusions:

**Impacte de les particions Train-Test:**

No hi ha una variació significativa en el rendiment del model depenent de la proporció de les particions de train i test. Les mètriques de rendiment augmenten de manera lineal, amb un augment del 1% a 2% quan la partició de train passa del 20% al 95%.

**Impacte de la mida del diccionari:**

La mida del diccionari influeix de manera considerable en el rendiment del model. Es pot observar una diferència d'un 8-10% en totes les mètriques segons si s'utilitza un diccionari petit o gran.

La disminució del rendiment és més marcada quan la mida del diccionari baixa de les 300.000 paraules. Això indica que una mida de diccionari més petita pot fer perdre informació rellevant per al model, afectant la seva precisió.

**Relació entre la mida del conjunt de train i la mida del diccionari:**

Quan augmenta la mida del conjunt de train, el model tendeix a rendir pitjor, malgrat que el diccionari es manté fix. Això es pot deure a que, amb conjunts de train més grans, només es fa servir una petita porció del diccionari generat, possiblement perdent paraules importants. En canvi, amb conjunts més petits, es fa servir una part més gran del diccionari, el que pot resultar en un rendiment millor.

**Millora amb Laplace Smoothing:**

L'ús del Laplace Smoothing millora el rendiment del model, especialment en el recall i, per tant, en el F1-score. Aquest efecte és positiu per a la identificació de casos positius, indicant que el suavitzat ajuda el model a ser més precís en la detecció d'aquests casos.

De les 3 pràctiques de la assignatura Coneixement, Raonament i Incertesa, em quedo amb aquesta.